



Optimización de sinopsis de libros para motores de búsqueda generativa (GEO) mediante la predicción de la probabilidad de citación con aprendizaje automático

Autor:

Ing. Luis José Paredes Ramirez

Director:

Dr. Ing. Juan Manuel Rodríguez (Universidad de Buenos Aires)

Codirector:

Sebastian Pellizzeri (Penguin Random House Grupo Editorial)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 08 de agosto de 2026 y el 13 de octubre de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar	5
2. Identificación y análisis de los interesados	7
3. Propósito del proyecto	7
4. Alcance del proyecto	7
5. Supuestos del proyecto.	9
6. Product Backlog	10
7. Criterios de aceptación de historias de usuario	11
8. Fases de CRISP-DM	13
9. Desglose del trabajo en tareas	14
10. Planificación de Sprints	16
11. Diagrama de Gantt (sprints)	18
12. Gobernanza de datos	20
12.1 Cumplimiento normativo	20
12.2 Ética en el uso de inteligencia artificial	21
13. Gestión de riesgos	22
14. Sprint Review	23
15. Sprint Retrospective	24

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	08 de agosto de 2026
1	Se completa hasta el punto 5 inclusive	07 de septiembre de 2026
2	Se adapta el proyecto de SEO a GEO según nuevos requisitos. Se actualiza hasta el punto 5 inclusive	22 de septiembre de 2026
3	Se completan los puntos 6 a 9 inclusive	28 de septiembre de 2026

Acta de constitución del proyecto

Buenos Aires, 08 de agosto de 2026

Por medio de la presente se acuerda con el Ing. Luis José Paredes Ramirez que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Optimización de sinopsis de libros para motores de búsqueda generativa (GEO) mediante la predicción de la probabilidad de citación con aprendizaje automático” y consistirá en **el desarrollo de un sistema que optimiza las sinopsis del catálogo para motores de búsqueda generativa, mediante un modelo de aprendizaje automático que predice la probabilidad de citación de cada título y un generador basado en un modelo grande de lenguaje que reescribe las sinopsis conforme a esa predicción.** El trabajo tendrá un presupuesto preliminar estimado de **600** horas y un costo estimado de \$ **XXX**, con fecha de inicio el 08 de agosto de 2026 y fecha de presentación pública el 15 de mayo de 2027.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Victoria O'Donnell
Penguin Random House Grupo Editorial

Dr. Ing. Juan Manuel Rodríguez
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El proyecto se desarrolla en conjunto con Penguin Random House Grupo Editorial Argentina, empresa que edita, publica y distribuye libros en formato papel, digital y audio para lectores de todas las edades. El responsable se desempeña en esa organización como *Machine Learning Engineer*, condición que habilita el acceso al catálogo editorial, a los datos internos de posicionamiento, a una cuenta paga de la interfaz de programación de aplicaciones (API, por su sigla en inglés) de DataForSEO y a las API de los motores de búsqueda generativa utilizados en el proyecto.

En la tienda en línea de la editorial [1], la sinopsis y las palabras clave (*keywords*) constituyen el principal contenido indexable de la ficha de cada libro y determinan en buena medida que un lector potencial encuentre el título al buscar por género, autor o temática. El texto de la sinopsis se redacta con criterio editorial y no contempla la demanda real de búsqueda.

La optimización para motores de búsqueda (SEO, por su sigla en inglés) reúne las técnicas que mejoran la posición de un sitio dentro de la página de resultados (SERP, por su sigla en inglés) de los buscadores tradicionales. Durante años, el tráfico se concentró en los primeros lugares de la SERP, lo que otorgaba alta visibilidad a los sitios mejor posicionados.

Sin embargo, recientemente cobraron auge los motores de búsqueda generativa, como ChatGPT y AI Overviews de Google, que responden a las consultas con un texto redactado por inteligencia artificial. Para construir esas respuestas, el motor puede realizar varias búsquedas web, recuperar un conjunto acotado de páginas y sintetizar su contenido en un texto que las cita como fuentes. Este mecanismo se conoce como generación aumentada por recuperación (RAG, por su sigla en inglés).

La optimización para motores de búsqueda generativa (GEO, por su sigla en inglés) reúne las técnicas que aumentan la probabilidad de que un contenido sea citado en esas respuestas. A diferencia del SEO, su unidad de éxito no es la posición en la SERP, sino la aparición en la respuesta del motor de búsqueda generativa. En este proyecto, esa aparición se mide como citación, es decir, como la inclusión de la ficha del libro entre las fuentes de la respuesta. La citación solo ocurre cuando el motor busca en la web, y no cuando responde a partir de lo aprendido en su entrenamiento.

Las suites comerciales de SEO estiman el volumen de búsqueda y la dificultad de cada *keyword*, y orientan la optimización hacia la posición en la SERP. Ese enfoque no alcanza en GEO, un canal nuevo y distinto, que requiere otra unidad de éxito y otras estrategias. Una buena posición orgánica no garantiza que el motor cite la página, y la elección de *keywords* no indica qué contenido favorece la citación. En consecuencia, estas herramientas no anticipan qué títulos del catálogo serán citados ni qué conviene modificar en sus sinopsis.

La solución propuesta traslada el foco hacia la citación, sobre la base de la autoridad temática que la editorial ya consolidó en SEO. Consta de dos etapas. En la primera, un modelo de aprendizaje automático (ML, por su sigla en inglés) estima, para cada par formado por un libro y un grupo de consultas de descubrimiento, la probabilidad de que la ficha del libro sea citada en las respuestas de los motores de búsqueda generativa, y ordena las características de contenido según su aporte a esa probabilidad. En la segunda, un generador basado en un modelo grande de lenguaje (LLM, por su sigla en inglés) reescribe la sinopsis e incorpora esas características, bajo restricciones de extensión, tono y fidelidad a la sinopsis original.

[1] <https://www.penguinlibros.com/ar/>

La propuesta de valor radica en mejorar la visibilidad del catálogo en los motores de búsqueda generativa, un canal emergente para el descubrimiento de libros, sin afectar el posicionamiento orgánico ya alcanzado. La innovación pasa por dos aspectos: el modelo se entrena con la señal de citación observada en los motores de búsqueda generativa evaluados, y la generación queda condicionada por esa señal y verificada de forma automática antes de la revisión editorial. Como caso de estudio se utiliza un conjunto de títulos del catálogo de la editorial, en géneros como la novela romántica, la fantasía juvenil, la no ficción y la autoayuda. En ese conjunto se prueban las sinopsis reescritas y se mide su impacto en la citación.

En la figura 1 se presenta el diagrama en bloques del sistema. El flujo parte de tres fuentes de datos: la API de DataForSEO, los datos internos de la editorial y las mediciones de citación recogidas de los motores de búsqueda generativa. El bloque de ingesta consolida esa información en un conjunto de datos único que vincula libro, consulta, motor, característica de contenido y tasa de citación observada. Sobre ese conjunto se construyen las variables que alimentan al modelo de predicción, cuya salida es la lista de características priorizadas para cada título.




Figura 1. Diagrama en bloques del sistema.

El generador de sinopsis recibe el texto original y esas características, y produce una versión candidata. Un módulo de verificación automática controla la similitud semántica con el texto original, la extensión y la presencia efectiva de las características priorizadas; solo las candidatas que superan estos controles pasan a revisión editorial.

Las sinopsis aprobadas se publican en un piloto controlado sobre un conjunto de títulos comparables por género y popularidad. Una parte de esos títulos recibe la sinopsis reescrita, como grupo experimental, y el resto conserva la original, como grupo de control. El seguimiento de ambos grupos, con mediciones repetidas, permite estimar el efecto de la reescritura y descontar los cambios de comportamiento de los motores. Esas mediciones realimentan el conjunto de datos y habilitan un nuevo entrenamiento del modelo.

2. Identificación y análisis de los interesados

El proyecto se desarrolla internamente por el equipo de Analítica Avanzada de Penguin Random House Grupo Editorial. En la tabla 1 se identifican los interesados del proyecto y el rol que ocupa cada uno.

Tabla 1. Identificación de los interesados.

Rol	Nombre y Apellido	Organización	Puesto
Auspiciante	-	Penguin Random House Editorial Grupo	
Cliente	Victoria O'Donnell	Penguin Random House Editorial Grupo	Científica de datos
Responsable	Ing. Luis José Paredes Ramirez	Penguin Random House Editorial Grupo	Machine Learning Engineer
Orientador	Dr. Ing. Juan Manuel Rodríguez	Universidad de Buenos Aires	Director del Trabajo Final
Orientador	Sebastian Pellizzeri	Penguin Random House Editorial Grupo	Codirector del Trabajo Final

- Auspiciante: la editorial aporta las horas de trabajo del responsable, el acceso a los datos internos y el crédito de la API de DataForSEO. Cualquier consumo por encima de lo previsto requiere una autorización expresa, de modo que conviene acotar las consultas al proveedor desde el diseño del conjunto de datos.
- Cliente: valida los entregables y define qué títulos integran el piloto. Su disponibilidad es acotada, por lo que las instancias de validación deben planificarse con anticipación y concentrarse en pocas reuniones.
- Orientadores: el director aporta el encuadre metodológico y la supervisión académica del trabajo final. El codirector aporta el conocimiento del negocio editorial y de los sistemas internos. Este último también fija prioridades dentro de la empresa.

3. Propósito del proyecto

El propósito de este proyecto es aumentar la visibilidad del catálogo de la editorial en los motores de búsqueda generativa, medida como la tasa de citación de sus fichas en las respuestas, sin resignar el posicionamiento orgánico ya consolidado.

4. Alcance del proyecto

El proyecto incluye:

- La construcción del conjunto de datos de citación.

- Diseño del conjunto de consultas de descubrimiento y del protocolo de medición.
- Medición repetida de la citación del catálogo en las respuestas con búsqueda web de los motores de búsqueda generativa.
 - Para el motor de búsqueda generativa de ChatGPT se utiliza la API de OpenAI.
 - Para el motor de búsqueda generativa AI Overviews de Google se utiliza la API de DataForSEO.
- Obtención de la posición de las fichas en las búsquedas que realizan los motores, mediante la API de DataForSEO, en calidad de variables de control.
- Incorporación de los datos internos de la editorial: catálogo y metadatos; indicadores de popularidad, como las ventas y las series históricas de Google Trends; y resultados de proyectos de SEO previos.
- Consolidación, limpieza y versionado del conjunto de datos.
- El análisis exploratorio de los datos y la construcción de las variables predictoras, incluida la extracción de las características de contenido con un LLM y su validación sobre una muestra etiquetada en forma manual.
- El desarrollo del modelo de predicción de la probabilidad de citación.
 - Entrenamiento y comparación entre modelos de aprendizaje automático.
 - Definición de la métrica de priorización de características de contenido por libro.
 - Validación mediante mediciones repetidas y controles de paráfrasis.
- El desarrollo del generador de sinopsis basado en un LLM comercial, con sus restricciones de extensión, tono y fidelidad, que aplica las técnicas de GEO compatibles con una sinopsis.
- El módulo de verificación automática de las sinopsis candidatas: fidelidad semántica respecto del texto original, extensión y presencia efectiva de las características priorizadas.
- La ejecución de un piloto controlado sobre un conjunto de títulos comparables por género y popularidad, dividido en un grupo experimental, que recibe las sinopsis aprobadas, y un grupo de control, que conserva las originales, con seguimiento de la citación y de la posición orgánica de ambos grupos durante la ventana de medición acordada.
- La documentación del sistema, el código fuente y la memoria del trabajo final.

El presente proyecto no incluye:

- La optimización de otros factores de GEO distintos de la sinopsis, tales como la estructura del sitio, los datos estructurados, las páginas de autor o de género y la presencia en fuentes externas de alta citación.
- Las respuestas que los motores generan sin realizar una búsqueda web, sobre las que la sinopsis publicada no tiene influencia.
- El entrenamiento o el alojamiento de un modelo de lenguaje propio, dado que se utilizan API comerciales.
- Cualquier intervención sobre los corpus de entrenamiento de los motores o la colocación paga en sus respuestas.
- La integración productiva con el gestor de contenidos de la tienda en línea: la carga de las sinopsis del piloto se realiza por los canales que la editorial ya utiliza.

- El despliegue sobre la totalidad del catálogo ni la puesta en producción del sistema.
- La medición del impacto en ventas o en ingresos, que excede la ventana temporal del proyecto.
- La regionalización hacia otros mercados distintos de Argentina.
- La comparación con catálogos de otras editoriales.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se asume que:

- La editorial mantiene la autorización para utilizar el catálogo, las sinopsis y los datos internos de posicionamiento con fines académicos, y admite la publicación de resultados agregados en la memoria del trabajo final.
- El acceso a la API de DataForSEO continúa vigente durante toda la ejecución y el crédito contratado alcanza para el volumen de consultas previsto.
- Se dispone de acceso a las API de los motores de búsqueda generativa evaluados, con un crédito suficiente para el volumen de mediciones repetidas previsto y un costo por consulta compatible con el presupuesto asignado.
- Las API utilizadas informan si cada respuesta incluyó una búsqueda web y cuáles fueron las fuentes citadas.
- El comportamiento de búsqueda de los motores consultados mediante sus API es representativo del que observan los usuarios en las aplicaciones de cada motor.
- El conjunto acotado de consultas de descubrimiento representa de forma adecuada las intenciones reales de los lectores para los géneros incluidos en el estudio.
- El catálogo contiene suficientes títulos comparables por género y popularidad para conformar un grupo experimental y un grupo de control de tamaño adecuado.
- El área de marketing digital habilita la publicación de las sinopsis del piloto dentro de los plazos planificados.
- El equipo editorial dispone de tiempo para revisar las sinopsis candidatas y la muestra con la que se define el umbral de fidelidad.
- Los cambios de comportamiento de los motores de búsqueda generativa durante la ventana de medición afectan por igual al grupo experimental y al grupo de control, de modo que la comparación entre ambos aísla el efecto de las sinopsis modificadas. Las mediciones se repiten para atenuar la variabilidad entre ejecuciones.
- La cantidad de citas observadas en las rondas de medición es suficiente para entrenar y validar el modelo.
- El responsable dispone de una carga horaria semanal sostenida y compatible con el cronograma, y cuenta con el equipamiento y los servicios de cómputo necesarios.
- Las condiciones macroeconómicas no alteran de forma significativa el costo en pesos de los servicios contratados en moneda extranjera.

6. Product Backlog

El *product backlog* organiza las historias de usuario en bloques funcionales del proyecto llamadas épicas. Cada historia sigue el formato:

Como <rol>, quiero <funcionalidad>, para <motivo/valor>.

Cada historia indica su prioridad y su ponderación en *story points*. Los criterios de aceptación se detallan en la sección 7.

El criterio para calcular los *story points* pondera tres dimensiones y suma sus pesos:

- Dificultad, entendida como la cantidad de trabajo: baja vale 1, media vale 3 y alta vale 5.
- Complejidad, entendida como el nivel técnico: baja vale 1, media vale 3 y alta vale 5.
- Incertidumbre, entendida como el riesgo o la novedad: baja vale 2, media vale 3 y alta vale 5.

La suma de los tres pesos se redondea al siguiente número de la serie de Fibonacci. Esto es: 1, 2, 3, 5, 8, 13, 21 y 34. El criterio sobreestima antes que subestimar.

Épica 1: construcción del conjunto de datos de citación

HU1. Como *Machine Learning Engineer*, quiero medir la citación de los títulos en los motores de búsqueda generativa para construir un conjunto de datos confiable. Prioridad: alta. *Story points*: dificultad: 5, complejidad: 5, incertidumbre: 5; la suma es 15 y se redondea a 21.

HU2. Como *Machine Learning Engineer*, quiero consolidar la posición de las fichas en las búsquedas que realizan los motores y los datos internos de popularidad, para controlar su efecto en la predicción de la citación. Prioridad: alta. *Story points*: dificultad: 3, complejidad: 5, incertidumbre: 3; la suma es 11 y se redondea a 13.

Épica 2: predicción de la probabilidad de citación

HU3. Como científico de datos, quiero entrenar un modelo que aprenda, a partir de las fichas citadas por los motores de búsqueda generativa, qué características de contenido se asocian con la citación, para priorizarlas en cada título. Prioridad: alta. *Story points*: dificultad: 5, complejidad: 3, incertidumbre: 5; la suma es 13.

HU4. Como científico de datos, quiero validar el modelo con mediciones repetidas para asegurar que sus predicciones son estables. Prioridad: alta. *Story points*: dificultad: 3, complejidad: 5, incertidumbre: 5; la suma es 13.

Épica 3: generación y verificación de sinopsis

HU5. Como editor, quiero que el sistema sugiera una sinopsis optimizada para motores de búsqueda generativa para aumentar su probabilidad de citación. Prioridad: alta. *Story points*: dificultad: 3, complejidad: 5, incertidumbre: 3; la suma es 11 y se redondea a 13.

HU6. Como editor, quiero que la sinopsis sugerida preserve la fidelidad de la sinopsis original para utilizarla en la tienda en línea. Prioridad: media. *Story points*: dificultad: 3, complejidad: 5, incertidumbre: 2; la suma es 10 y se redondea a 13.

Épica 4: piloto y medición de resultados

HU7. Como analista de marketing digital, quiero seguir la citación de las sinopsis publicadas en el piloto para medir la mejora frente a un grupo de control de títulos comparables. Prioridad: alta. *Story points*: dificultad: 5, complejidad: 5, incertidumbre: 5; la suma es 15 y se redondea a 21.

HU8. Como cliente, quiero un informe claro de los resultados del piloto para decidir la continuidad del proyecto. Prioridad: media. *Story points*: dificultad: 3, complejidad: 1, incertidumbre: 2; la suma es 6 y se redondea a 8.

7. Criterios de aceptación de historias de usuario

Cada historia de usuario cuenta con criterios de aceptación medibles y verificables, que definen cuándo la funcionalidad se considera cumplida.

Épica 1: construcción del conjunto de datos de citación

Criterios de aceptación de la HU1:

- Se consulta cada título con un conjunto fijo de consultas en los motores de búsqueda generativa, con la búsqueda web habilitada y diez repeticiones por consulta.
- Se registra, para cada respuesta, si el motor realizó una búsqueda web y, cuando la API lo informa, qué búsquedas ejecutó.
- En las respuestas con búsqueda, se registra si la ficha del título figura entre las fuentes citadas.

Criterios de aceptación de la HU2:

- Cada registro vincula título, consulta, motor, variables de control y tasa de citación.
- Se obtiene, mediante DataForSEO, la posición de las fichas en las búsquedas registradas de cada motor.
- Se integran los datos internos de popularidad y los metadatos del catálogo.
- Se documentan el origen y las transformaciones de cada variable.

Épica 2: predicción de la probabilidad de citación

Criterios de aceptación de la HU3:

- Las características de contenido se extraen de cada sinopsis y su concordancia se valida sobre una muestra etiquetada en forma manual.

- Se comparan al menos dos modelos y se selecciona el de mejor desempeño.
- El modelo predice la probabilidad de citación y ordena las características por su aporte.
- El desempeño se mide sobre títulos excluidos del entrenamiento, mediante validación cruzada agrupada por título, con dos métricas: el error cuadrático medio entre la tasa de citación predicha y la observada, ponderado por la cantidad de respuestas, y la correlación de Spearman entre ambas tasas.
- Se reporta cuánto mejoran esas métricas al agregar las características de contenido a un modelo que solo usa variables de control.

Criterios de aceptación de la HU4:

- La validación usa mediciones repetidas y control de paráfrasis.
- Se reporta la variabilidad de las predicciones entre ejecuciones.

Épica 3: generación y verificación de sinopsis

Criterios de aceptación de la HU5:

- La sinopsis sugerida tiene mayor probabilidad de ser citada por los motores de búsqueda generativa con búsqueda web activa.
- Para cada título, se optimiza para los mismos grupos de consultas con los que se construyó el conjunto de datos de citación.

Criterios de aceptación de la HU6:

- La sinopsis generada respeta el límite de extensión y el tono editorial.
- Incorpora las características priorizadas por el modelo.
- Conserva la fidelidad semántica con el texto original por encima del umbral.

Épica 4: piloto y medición de resultados

Criterios de aceptación de la HU7:

- Se conforman un grupo experimental y un grupo de control con títulos comparables por género y popularidad.
- Se mide la citación de ambos grupos durante la ventana acordada.
- Se registra la posición orgánica de las fichas de ambos grupos en cada ronda de medición.
- Se estima el efecto de la reescritura como la diferencia en la evolución de la citación entre ambos grupos.
- Los resultados distinguen la señal del ruido mediante mediciones repetidas.

Criterios de aceptación de la HU8:

- El informe presenta los resultados del piloto frente al grupo de control, con sus intervalos de variabilidad.
- Incluye visualizaciones claras y las limitaciones del análisis.
- Se entrega en un formato que el cliente puede revisar y aprobar.

8. Fases de CRISP-DM

1. Comprensión del negocio

- Objetivo: aumentar la visibilidad del catálogo de la editorial en los motores de búsqueda generativa, medida como la tasa de citación de las fichas en las respuestas con búsqueda web.
- Valor agregado: presencia del catálogo en un canal emergente para el descubrimiento de libros, sin resignar el posicionamiento orgánico ya consolidado, mediante un procedimiento basado en datos y aplicable a todo el catálogo.
- Métricas de éxito del negocio, con valores a consensuar con el cliente:
 - Tasa de citación del grupo experimental respecto del grupo de control: aumento relativo $\geq 20\%$, con significación estadística.
 - Posición orgánica de las fichas del grupo experimental: sin caída respecto del grupo de control.
 - Sinopsis candidatas aprobadas en la revisión editorial: $\geq 70\%$.

2. Comprensión de los datos

- Tipo: respuestas de los motores, con su texto, sus fuentes citadas y las búsquedas ejecutadas; sinopsis y metadatos del catálogo; posiciones de las fichas en los buscadores e indicadores de popularidad.
- Origen: API de OpenAI para ChatGPT con búsqueda web; API de DataForSEO para AI Overviews de Google y para las posiciones en los buscadores; datos internos de la editorial para el catálogo, las ventas y las series de Google Trends.
- Cantidad esperada: del orden de miles de respuestas por ronda de medición, sobre cientos de títulos elegibles de los géneros del estudio.
- Calidad: alta variabilidad entre ejecuciones y entre paráfrasis de una misma consulta, citas escasas y fuentes que deben asociarse a cada título. Se requieren mediciones repetidas y control de calidad del procesamiento.

3. Preparación de los datos

- Características clave: variables de contenido de la sinopsis, extraídas con un LLM y validadas sobre una muestra etiquetada en forma manual; coincidencia entre la sinopsis y cada grupo de consultas; variables de control de posición, popularidad y metadatos.
- Transformaciones:
 - Descarte de las respuestas sin búsqueda web y asociación de las fuentes citadas con la ficha de cada título.

- Agregación por título, grupo de consultas y motor: tasa de citación y cantidad de respuestas.
- Restricción a los pares elegibles, en los que el título es una respuesta pertinente para el grupo de consultas.
- Partición agrupada por título, sin fuga de información entre entrenamiento y prueba.

4. Modelado

- Tipo de problema: regresión de una proporción, es decir, de la cantidad de citas sobre la cantidad de respuestas con búsqueda, para estimar la probabilidad de citación por título, grupo de consultas y motor.
- Algoritmos posibles:
 - Regresión logística regularizada, como modelo lineal interpretable.
 - Árboles de decisión potenciados por gradiente, como LightGBM o CatBoost, con función de pérdida binomial ponderada por la cantidad de respuestas.
- Priorización: para cada título, se estima la variación de la probabilidad predicha al modificar cada característica de contenido, y se ordenan las características según esa ganancia.
- Selección y ajuste: búsqueda de hiperparámetros con validación cruzada agrupada por título, regularización y registro de la versión del modelo.

5. Evaluación del modelo

- Métricas técnicas: error cuadrático medio, ponderado por la cantidad de respuestas, y correlación de Spearman entre la tasa de citación predicha y la observada, sobre títulos excluidos del entrenamiento.
- Criterios mínimos: el modelo seleccionado obtiene menor error y mayor correlación que un modelo de referencia que predice la tasa media de cada grupo de consultas y motor. Además, se reporta el aporte de las características de contenido respecto de un modelo que solo usa variables de control.
- Estabilidad: correlación de las tasas de citación entre rondas de medición y desempeño sobre paráfrasis no vistas.
- Verificación humana: revisión de una muestra de respuestas procesadas, de características extraídas y de prioridades asignadas.

6. Despliegue

- Tipo de despliegue: piloto controlado sobre un conjunto de títulos comparables por género y popularidad, con publicación de las sinopsis aprobadas en el grupo experimental por los canales que la editorial ya utiliza.
- Herramientas: repositorio de código, versionado del conjunto de datos y del modelo, y registro de las respuestas de los motores y de las sinopsis publicadas.
- Operación del piloto: mediciones repetidas en ambos grupos durante la ventana acordada, sinopsis del grupo de control sin cambios y nuevo entrenamiento con los datos obtenidos. La puesta en producción queda fuera de alcance.

9. Desglose del trabajo en tareas

A partir de cada historia de usuario definida en la sección 6 se descompone el trabajo en tareas técnicas concretas, medibles y acotadas en el tiempo.

Historia	Tarea técnica	Estimación	Prioridad
HU1	Definir el conjunto de consultas y el protocolo de diez repeticiones	6 h	Alta
HU1	Automatizar la consulta a ChatGPT y a AI Overviews con la búsqueda web habilitada	8 h	Alta
HU1	Registrar las búsquedas ejecutadas y asociar las fuentes citadas con la ficha de cada título	8 h	Alta
HU2	Obtener la posición de las fichas en las búsquedas de los motores mediante DataForSEO	6 h	Alta
HU2	Integrar los datos internos de popularidad y consolidar el conjunto de datos	8 h	Media
HU3	Definir las características de contenido y extraerlas con un LLM	6 h	Alta
HU3	Etiquetar una muestra en forma manual y medir la concordancia con el LLM	6 h	Alta
HU3	Entrenar y comparar al menos dos modelos con validación cruzada agrupada por título	8 h	Alta
HU3	Calcular las métricas de desempeño y el aporte de las características de contenido	5 h	Alta
HU3	Implementar la priorización de características por título	6 h	Alta
HU4	Implementar el protocolo de validación con repeticiones y paráfrasis	6 h	Alta
HU4	Reentrenar el modelo por ronda de medición y reportar la variabilidad de las predicciones	5 h	Media
HU5	Diseñar los <i>prompts</i> del generador a partir de las características priorizadas y de los grupos de consultas de cada título	5 h	Alta
HU5	Desarrollar el generador de sinopsis basado en un LLM	8 h	Alta
HU5	Estimar con el modelo la probabilidad de citación de la sinopsis sugerida frente a la original	4 h	Alta
HU6	Implementar el control de similitud semántica, extensión y presencia de las características priorizadas	6 h	Alta
HU6	Definir el umbral de fidelidad con una muestra revisada por el equipo editorial	4 h	Media
HU6	Integrar el rechazo automático y el pase a revisión editorial	4 h	Media
HU7	Seleccionar los títulos comparables y asignar los grupos experimental y de control	5 h	Alta
HU7	Publicar las sinopsis del grupo experimental y configurar el seguimiento de ambos grupos	6 h	Alta
HU7	Ejecutar la campaña de medición del piloto con repeticiones	8 h	Alta
HU7	Estimar el efecto de la reescritura como la diferencia en la evolución de la citación entre grupos	6 h	Alta
HU7	Registrar en cada ronda de medición la posición orgánica de las fichas de ambos grupos, a partir de las páginas de resultados de DataForSEO	3 h	Media
HU8	Calcular los intervalos de variabilidad del efecto estimado	4 h	Media
HU8	Elaborar el informe con visualizaciones y limitaciones	4 h	Media

10. Planificación de Sprints

En la tabla 2 se distribuyen las 600 h del proyecto en once *sprints*, precedidos por un *sprint* 0 de planificación. Las tareas técnicas son las de la sección 9, con una estimación que incorpora el tiempo de prueba, iteración y documentación. Se suman, además, las pruebas integradas, la documentación, la escritura de la memoria y la preparación de la defensa.

Tabla 2. Planificación de los *sprints*.

Sprint	HU o fase	Tarea	Horas	Responsable	% Completado
Sprint 0	Planificación	Relevar el estado del arte de GEO	8 h	Ing. Paredes	100 %
Sprint 0	Planificación	Reorientar el proyecto de SEO a GEO	12 h	Ing. Paredes	100 %
Sprint 0	Planificación	Elaboración del plan de trabajo	24 h	Ing. Paredes	70 %
Sprint 0	Planificación	Validar el plan con los orientadores y el cliente	4 h	Ing. Paredes	50 %
Sprint 1	HU1	Definir las consultas y el protocolo de medición	15 h	Ing. Paredes	0 %
Sprint 1	HU1	Automatizar las consultas a ChatGPT y a AI Overviews	18 h	Ing. Paredes	0 %
Sprint 1	HU1	Registrar las búsquedas y asociar las fuentes citadas	17 h	Ing. Paredes	0 %
Sprint 2	HU2	Obtener la posición de las fichas con DataFor-SEO	14 h	Ing. Paredes	0 %
Sprint 2	HU2	Consolidar el conjunto de datos con los datos internos	20 h	Ing. Paredes	0 %
Sprint 2	HU3	Definir y extraer las características con un LLM	16 h	Ing. Paredes	0 %
Sprint 3	HU3	Etiquetar una muestra y medir la concordancia con el LLM	10 h	Ing. Paredes	0 %
Sprint 3	HU3	Entrenar y comparar al menos dos modelos	18 h	Ing. Paredes	0 %
Sprint 3	HU3	Calcular las métricas y el aporte de las características	10 h	Ing. Paredes	0 %
Sprint 3	HU3	Implementar la priorización de características por título	12 h	Ing. Paredes	0 %

Sprint	HU o fase	Tarea	Horas	Responsable	% Completado
Sprint 4	HU4	Implementar el protocolo de validación	18 h	Ing. Paredes	0 %
Sprint 4	HU4	Reentrenar por ronda y reportar la variabilidad	18 h	Ing. Paredes	0 %
Sprint 4	HU5	Diseñar los <i>prompts</i> del generador	12 h	Ing. Paredes	0 %
Sprint 5	HU5	Desarrollar el generador de sinopsis basado en un LLM	22 h	Ing. Paredes	0 %
Sprint 5	HU5	Estimar la probabilidad de citación de la sinopsis sugerida	10 h	Ing. Paredes	0 %
Sprint 5	HU6	Implementar el control de similitud, extensión y características	16 h	Ing. Paredes	0 %
Sprint 6	HU6	Definir el umbral de fidelidad con el equipo editorial	10 h	Ing. Paredes	0 %
Sprint 6	HU6	Integrar el rechazo automático y el pase a revisión editorial	10 h	Ing. Paredes	0 %
Sprint 6	Pruebas	Ejecutar pruebas integradas del flujo completo	30 h	Ing. Paredes	0 %
Sprint 7	Pruebas	Corregir errores y ajustar el sistema	28 h	Ing. Paredes	0 %
Sprint 7	HU7	Seleccionar los títulos y asignar los grupos del piloto	10 h	Ing. Paredes	0 %
Sprint 7	HU7	Publicar las sinopsis y configurar el seguimiento	12 h	Ing. Paredes	0 %
Sprint 8	HU7	Ejecutar la campaña de medición del piloto	28 h	Ing. Paredes	0 %
Sprint 8	HU7	Registrar la posición orgánica de ambos grupos	8 h	Ing. Paredes	0 %
Sprint 8	HU7	Estimar el efecto de la reescritura entre grupos	16 h	Ing. Paredes	0 %

Sprint	HU o fase	Tarea	Horas	Responsable	% Completado
Sprint 9	HU8	Calcular los intervalos de variabilidad del efecto estimado	12 h	Ing. Paredes	0 %
Sprint 9	HU8	Elaborar el informe con visualizaciones y limitaciones	16 h	Ing. Paredes	0 %
Sprint 9	Documentación	Documentar los módulos implementados	22 h	Ing. Paredes	0 %
Sprint 10	Escritura	Redactar la memoria: introducción y estado del arte	32 h	Ing. Paredes	0 %
Sprint 10	Escritura	Redactar la memoria: desarrollo y resultados	30 h	Ing. Paredes	0 %
Sprint 11	Escritura	Incorporar el <i>feedback</i> del director	12 h	Ing. Paredes	0 %
Sprint 11	Escritura	Redactar la memoria: conclusiones y versión final	10 h	Ing. Paredes	0 %
Sprint 11	Defensa	Preparar la exposición y ensayar la defensa	20 h	Ing. Paredes	0 %

11. Diagrama de Gantt (sprints)

En la tabla 3 se indican las fechas, la duración y las horas de cada *sprint*, que suman las 600 h del proyecto, y en la figura 2 se presenta el diagrama de Gantt.

Tabla 3. Cronograma de los *sprints*.

Sprint	Inicio	Fin	Semanas	Contenido	Horas
Sprint 0	08/08/2026	13/10/2026	9,5	Planificación	48 h
Sprint 1	14/10/2026	27/10/2026	2	HU1	50 h
Sprint 2	28/10/2026	10/11/2026	2	HU2 y HU3	50 h
Sprint 3	11/11/2026	24/11/2026	2	HU3	50 h
Sprint 4	25/11/2026	08/12/2026	2	HU4 y HU5	48 h
Sprint 5	09/12/2026	22/12/2026	2	HU5 y HU6	48 h
Receso	23/12/2026	05/01/2027	2	Receso de fin de año	–
Sprint 6	06/01/2027	19/01/2027	2	HU6 y pruebas	50 h
Sprint 7	20/01/2027	02/02/2027	2	Pruebas y HU7	50 h
Sprint 8	03/02/2027	02/03/2027	4	HU7	52 h
Sprint 9	03/03/2027	16/03/2027	2	HU8 y documentación	50 h
Sprint 10	17/03/2027	20/04/2027	5	Escritura	62 h
Sprint 11	21/04/2027	15/05/2027	3,5	Escritura y defensa	42 h

Según lo recomendado en la asignatura, la etapa técnica concluye el 16 de marzo de 2027, dos meses antes de la defensa. Las tareas se encadenan en forma secuencial, ya que recaen en un único responsable, y conforman el camino crítico.




Figura 2. Diagrama de Gantt del proyecto.

12. Gobernanza de datos

El proyecto utiliza tres tipos de datos: los datos internos de la editorial, las respuestas de los motores de búsqueda generativa y las posiciones de las fichas en los buscadores. En esta sección se analizan el marco normativo que rige su uso y los aspectos éticos de la solución.

12.1. Cumplimiento normativo

Dado que el proyecto se desarrolla en Argentina, resultan aplicables las siguientes normativas:

- Ley 25.326 de Protección de los Datos Personales: el proyecto no trata datos de lectores ni de clientes, y las ventas se utilizan agregadas por título. Los únicos datos personales son los nombres de los autores, que ya son públicos en el catálogo.
- Ley 11.723 de Propiedad Intelectual: las sinopsis son obras protegidas cuya titularidad corresponde a la editorial o a los autores. Su uso y su reescritura requieren la autorización de la editorial, que además decide la publicación de cada versión.

El Reglamento General de Protección de Datos de la Unión Europea (GDPR, por su sigla en inglés) no resulta aplicable, ya que no se tratan datos de residentes de la Unión Europea.

Las fuentes de datos, las herramientas y los modelos se emplean bajo las siguientes condiciones:

- Datos internos: el catálogo, los metadatos, las ventas y los resultados de proyectos de SEO previos son propiedad de la editorial y tienen carácter confidencial. Se utilizan con su autorización, solo con fines académicos, y no se publican ni se comparten con terceros.
- Respuestas de los motores: se obtienen mediante la API de OpenAI y la API de DataForSEO, servicios contratados cuyo uso se rige por sus términos de servicio. Las consultas respetan los límites de uso de cada proveedor, y las respuestas se almacenan solo para medir la citación, sin redistribuirse.
- Herramientas y modelos: las bibliotecas previstas tienen licencias permisivas, como BSD de 3 cláusulas en scikit-learn, MIT en LightGBM y Apache 2.0 en CatBoost. El LLM comercial se utiliza mediante su API, sin acceso a sus pesos, y el modelo de *embeddings* se elegirá entre los que cuenten con una licencia permisiva.

En consecuencia, el proyecto es legalmente viable, siempre que se adopten las siguientes medidas:

- Autorización escrita de la editorial para el uso de los datos internos con fines académicos.
- Confidencialidad de los datos propietarios: la memoria, la defensa y cualquier otra publicación incluyen solo resultados agregados y ejemplos autorizados por la editorial, y el conjunto de datos no se publica.
- Envío a las API externas solo de información ya publicada en la tienda en línea, previa verificación de las políticas de retención y uso de datos de cada proveedor.

- Almacenamiento de los datos en repositorios de acceso restringido, con las credenciales de las API fuera del código fuente.
- Trazabilidad del origen y de las transformaciones de cada variable, y versionado de los datos, del modelo y de las sinopsis generadas.

12.2. Ética en el uso de inteligencia artificial

Los datos y los modelos del proyecto presentan los siguientes sesgos posibles:

- Sesgo de popularidad: los motores tienden a citar los títulos y las marcas de mayor difusión. El modelo podría atribuir a las características de contenido un efecto que corresponde a la popularidad, y favorecer a los títulos más vendidos en desmedro del fondo de catálogo. Por ese motivo, la popularidad y la posición orgánica se incorporan como variables de control.
- Sesgo de selección: las consultas y los géneros del estudio son una muestra acotada de las intenciones de los lectores. Los resultados no se extienden a otros géneros sin una nueva validación.
- Sesgo de los modelos de lenguaje: el LLM puede extraer de forma errónea las características o introducir estereotipos culturales o de género en las sinopsis. La concordancia con un etiquetado manual y la revisión editorial acotan este riesgo.
- Sesgo geográfico y de idioma: los motores pueden preferir fuentes de otros mercados de habla hispana o en otro idioma. Por eso, la medición registra el dominio de cada fuente citada.

En cuanto al impacto social, el sistema beneficia a la editorial y a sus autores, y ofrece a los lectores información más clara sobre cada libro. Sin embargo, presenta los siguientes riesgos:

- Desinformación: una sinopsis optimizada podría exagerar o atribuir al libro contenidos que no tiene.
- Homogeneización: la reescritura masiva podría uniformar las sinopsis y diluir la voz editorial.

Para prevenir y mitigar estos riesgos, se adoptan las siguientes medidas:

- Supervisión humana: ninguna sinopsis se publica sin la aprobación del equipo editorial.
- Verificación automática: cada candidata debe superar el umbral de fidelidad semántica respecto del texto original.
- Trazabilidad y auditoría: se registran las versiones de los datos, del modelo, de los *prompts* y de las candidatas, y se revisa la priorización por género y por motor en cada ronda de medición.
- Política de uso responsable: el sistema se aplica solo al catálogo propio, no emplea técnicas engañosas ni contenido pensado exclusivamente para los motores, y el uso de inteligencia artificial se declara conforme a la política de la editorial.

El proyecto busca mejorar la visibilidad del catálogo con información fiel y verificable, y no mediante la manipulación de los motores. La equidad se resguarda con el control de la popularidad y el análisis por género, y la transparencia, con la documentación de los límites del sistema y la revisión humana de cada sinopsis publicada.

13. Gestión de riesgos

a) Identificación de los riesgos (al menos cinco) y estimación de sus consecuencias:

Riesgo 1: detallar el riesgo (riesgo es algo que si ocurre altera los planes previstos de forma negativa)

- Severidad (S): mientras más severo, más alto es el número (usar números del 1 al 10). Justificar el motivo por el cual se asigna determinado número de severidad (S).
- Probabilidad de ocurrencia (O): mientras más probable, más alto es el número (usar del 1 al 10). Justificar el motivo por el cual se asigna determinado número de (O).

Riesgo 2:

- Severidad (S): X.
Justificación...
- Ocurrencia (O): Y.
Justificación...

Riesgo 3:

- Severidad (S): X.
Justificación...
- Ocurrencia (O): Y.
Justificación...

b) Tabla de gestión de riesgos: (El RPN se calcula como $RPN=S \times O$)

Riesgo	S	O	RPN	S*	O*	RPN*

Criterio adoptado:

Se tomarán medidas de mitigación en los riesgos cuyos números de RPN sean mayores a...

Nota: los valores marcados con (*) en la tabla corresponden luego de haber aplicado la mitigación.

c) Plan de mitigación de los riesgos que originalmente excedían el RPN máximo establecido:

Riesgo 1: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).
Nueva asignación de S y O, con su respectiva justificación:

- Severidad (S*): mientras más severo, más alto es el número (usar números del 1 al 10). Justificar el motivo por el cual se asigna determinado número de severidad (S).
- Probabilidad de ocurrencia (O*): mientras más probable, más alto es el número (usar del 1 al 10). Justificar el motivo por el cual se asigna determinado número de (O).

Riesgo 2: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).

Riesgo 3: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).

14. Sprint Review

La revisión de sprint (*Sprint Review*) es una práctica fundamental en metodologías ágiles. Consiste en revisar y evaluar lo que se ha completado al finalizar un sprint. En esta instancia, se presentan los avances y se verifica si las funcionalidades cumplen con los criterios de aceptación establecidos. También se identifican entregables parciales y se consideran ajustes si es necesario.

Aunque el proyecto aún se encuentre en etapa de planificación, esta sección permite proyectar cómo se evaluarán las funcionalidades más importantes del backlog. Esta mirada anticipada favorece la planificación enfocada en valor y permite reflexionar sobre posibles obstáculos.

Objetivo: anticipar cómo se evaluará el avance del proyecto a medida que se desarrollen las funcionalidades, utilizando como base al menos cuatro historias de usuario del *Product Backlog*.

Seleccionar al menos 4 HU del Product Backlog. Para cada una, completar la siguiente tabla de revisión proyectada:

Formato sugerido:

HU seleccionada	Tareas asociadas	Entregable esperado	¿Cómo sabrás que está cumplida?	Observaciones o riesgos
HU1	Tarea 1	Módulo funcional	Cumple criterios de aceptación definidos	Falta validar con el tutor
	Tarea 2			
HU3	Tarea 1	Reporte generado	Exportación disponible y clara	Requiere datos reales
	Tarea 2			
HU5	Tarea 1	Panel de gestión	Roles diferenciados operativos	Riesgo en integración
	Tarea 2			
HU7	Tarea 1	Informe trimestral	PDF con gráficos y evolución	Puede faltar tiempo para ajustes
	Tarea 2			

15. Sprint Retrospective

La retrospectiva de sprint es una práctica orientada a la mejora continua. Al finalizar un sprint, el equipo (o el alumno, si trabaja de forma individual) reflexiona sobre lo que funcionó bien, lo que puede mejorarse y qué acciones concretas pueden implementarse para trabajar mejor en el futuro.

Durante la cursada se propuso el uso de la **Estrella de la Retrospectiva**, que organiza la reflexión en torno a cinco ejes:

- ¿Qué hacer más?
- ¿Qué hacer menos?
- ¿Qué mantener?
- ¿Qué empezar a hacer?
- ¿Qué dejar de hacer?

Aun en una etapa temprana, esta herramienta permite que el alumno planifique su forma de trabajar, identifique anticipadamente posibles dificultades y diseñe estrategias de organización personal.

Objetivo: reflexionar sobre las condiciones iniciales del proyecto, identificando fortalezas, posibles dificultades y estrategias de mejora, incluso antes del inicio del desarrollo.

Completar la siguiente tabla tomando como referencia los cinco ejes de la Estrella de la Retrospectiva (*Starfish* o estrella de mar). Esta instancia te ayudará a definir buenas prácticas desde el inicio y prepararte para enfrentar el trabajo de forma organizada y flexible. Se deberá completar la tabla al menos para 3 sprints técnicos y 1 no técnico.

Formato sugerido:

Sprint tipo y N°	¿Qué hacer más?	¿Qué hacer menos?	¿Qué mantener?	¿Qué empezar a hacer?	¿Qué dejar de hacer?
Sprint técnico - 1	Validaciones continuas con el alumno	Cambios sin versión registrada	Pruebas con datos simulados	Documentar cambios propuestos	Ajustes sin análisis de impacto
Sprint técnico - 2	Verificar configuraciones en múltiples escenarios	Modificar parámetros sin guardar historial	Perfiles reutilizables	Usar logs para configuración	Repetir pruebas manuales innecesarias
Sprint técnico - 8	Comparar correlaciones con casos previos	Cambiar parámetros sin justificar	Revisión cruzada de métricas	Anotar configuraciones usadas	Trabajar sin respaldo de datos
Sprint no técnico - 12 (por ej.: “Defensa”)	Ensayos orales con feedback	Cambiar contenidos en la memoria	Material visual claro	Dividir la presentación por bloques	Agregar gráficos difíciles de explicar