



Optimización de sinopsis de libros para motores de búsqueda generativos (GEO) mediante la predicción de la probabilidad de citación con aprendizaje automático

Autor:

Ing. Luis José Paredes Ramirez

Director:

Dr. Ing. Juan Manuel Rodríguez (Universidad de Buenos Aires)

Codirector:

Sebastian Pellizzeri (Penguin Random House Grupo Editorial)

*Esta planificación fue realizada en el curso de Gestión de proyectos
entre el 08 de agosto de 2026 y el 13 de octubre de 2026.*

Índice

1. Descripción técnica-conceptual del proyecto a realizar.	5
2. Identificación y análisis de los interesados	7
3. Propósito del proyecto	7
4. Alcance del proyecto	7
5. Supuestos del proyecto.	9
6. Product Backlog	9
7. Historias de usuarios (<i>Product backlog</i>).	10
8. Entregables principales del proyecto	11
9. Desglose del trabajo en tareas	11
10. Diagrama de Activity On Node.	12
11. Diagrama de Gantt	12
12. Presupuesto detallado del proyecto	15
13. Gestión de riesgos	15
14. Gestión de la calidad	16
15. Procesos de cierre	17

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	08 de agosto de 2026
1	Se completa hasta el punto 5 inclusive	07 de septiembre de 2026
2	Se adapta el proyecto de SEO a GEO segun nuevos requisitos. Se actualiza hasta el punto 5 inclusive	22 de septiembre de 2026

Acta de constitución del proyecto

Buenos Aires, 08 de agosto de 2026

Por medio de la presente se acuerda con el Ing. Luis José Paredes Ramirez que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará “Optimización de sinopsis de libros para motores de búsqueda generativos (GEO) mediante la predicción de la probabilidad de citación con aprendizaje automático” y consistirá en **el desarrollo de un sistema que optimiza las sinopsis del catálogo para motores de búsqueda generativos, mediante un modelo de aprendizaje automático que predice la probabilidad de citación de cada título y un generador basado en un modelo grande de lenguaje que reescribe las sinopsis conforme a esa predicción.** El trabajo tendrá un presupuesto preliminar estimado de **600** horas y un costo estimado de **\$ XXX**, con fecha de inicio el 08 de agosto de 2026 y fecha de presentación pública el 15 de mayo de 2027.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Victoria O'Donnell
Penguin Random House Grupo Editorial

Dr. Ing. Juan Manuel Rodríguez
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

El proyecto se desarrolla en conjunto con Penguin Random House Grupo Editorial Argentina, empresa que edita, publica y distribuye libros en formato papel, digital y audio para lectores de todas las edades. El responsable se desempeña en esa organización como *Machine Learning Engineer*, condición que habilita el acceso al catálogo editorial, a los datos internos de posicionamiento, a una cuenta paga de la interfaz de programación de aplicaciones (API, por su sigla en inglés) de DataForSEO y a las API de los motores generativos utilizados en el proyecto.

En la tienda en línea de la editorial [1], la sinopsis y las palabras clave (*keywords*) constituyen el principal contenido indexable de la ficha de cada libro y determinan en buena medida que un lector potencial encuentre el título al buscar por género, autor o temática. El texto de la sinopsis se redacta con criterio editorial y no contempla la demanda real de búsqueda.

La optimización para motores de búsqueda (SEO, por su sigla en inglés) reúne las técnicas que mejoran la posición de un sitio dentro de la página de resultados (SERP, por su sigla en inglés) de los buscadores tradicionales. Durante años, el tráfico se concentró en los primeros lugares de la SERP, lo que otorgaba alta visibilidad a los sitios mejor posicionados.

Sin embargo, recientemente cobraron auge los motores generativos, como ChatGPT y AI Overviews de Google, que responden a las consultas con un texto redactado por inteligencia artificial. Para construir esas respuestas, el motor puede realizar varias búsquedas web, recuperar un conjunto acotado de páginas y sintetizar su contenido en un texto que las cita como fuentes. Este mecanismo se conoce como generación aumentada por recuperación (RAG, por su sigla en inglés).

La optimización para motores generativos (GEO, por su sigla en inglés) reúne las técnicas que aumentan la probabilidad de que un contenido sea citado en esas respuestas. A diferencia del SEO, su unidad de éxito no es la posición en la SERP, sino la aparición en la respuesta del motor generativo. En este proyecto, esa aparición se mide como citación, es decir, como la inclusión de la ficha del libro entre las fuentes de la respuesta. La citación solo ocurre cuando el motor busca en la web, y no cuando responde a partir de lo aprendido en su entrenamiento.

Las suites comerciales de SEO estiman el volumen de búsqueda y la dificultad de cada *keyword*, y orientan la optimización hacia la posición en la SERP. Ese enfoque no alcanza en GEO, un canal nuevo y distinto, que requiere otra unidad de éxito y otras estrategias. Una buena posición orgánica no garantiza que el motor cite la página, y la elección de *keywords* no indica qué contenido favorece la citación. En consecuencia, estas herramientas no anticipan qué títulos del catálogo serán citados ni qué conviene modificar en sus sinopsis.

La solución propuesta traslada el foco hacia la citación, sobre la base de la autoridad temática que la editorial ya consolidó en SEO. Consta de dos etapas. En la primera, un modelo de aprendizaje automático (ML, por su sigla en inglés) estima, para cada par formado por un libro y un grupo de consultas de descubrimiento, la probabilidad de que la ficha del libro sea citada en las respuestas de los motores generativos, y ordena las características de contenido según su aporte a esa probabilidad. En la segunda, un generador basado en un modelo grande de lenguaje (LLM, por su sigla en inglés) reescribe la sinopsis e incorpora esas características, bajo restricciones de extensión, tono y fidelidad a la sinopsis original.

La propuesta de valor radica en mejorar la visibilidad del catálogo en los motores generativos, un canal emergente para el descubrimiento de libros, sin afectar el posicionamiento orgánico ya

[1] <https://www.penguinlibros.com/ar/>

alcanzado. La innovación pasa por dos aspectos: el modelo se entrena con la señal de citación observada en varios motores generativos, y la generación queda condicionada por esa señal y verificada de forma automática antes de la revisión editorial. Como caso de estudio se utiliza un conjunto de títulos del catálogo de la editorial, en géneros como la novela romántica, la fantasía juvenil, la no ficción y la autoayuda. En ese conjunto se prueban las sinopsis reescritas y se mide su impacto en la citación.

En la figura 1 se presenta el diagrama en bloques del sistema. El flujo parte de tres fuentes de datos: la API de DataForSEO, los datos internos de la editorial y las mediciones de citación recogidas de los motores generativos. El bloque de ingesta consolida esa información en un conjunto de datos único que vincula libro, consulta, motor, característica de contenido y tasa de citación observada. Sobre ese conjunto se construyen las variables que alimentan al modelo de predicción, cuya salida es la lista de características priorizadas para cada título.




Figura 1. Diagrama en bloques del sistema.

El generador de sinopsis recibe el texto original y esas características, y produce una versión candidata. Un módulo de verificación automática controla la similitud semántica con el texto original, la extensión y la presencia efectiva de las características priorizadas; solo las candidatas que superan estos controles pasan a revisión editorial.

Las sinopsis aprobadas se publican en un piloto controlado sobre un conjunto de títulos comparables por género y popularidad. Una parte de esos títulos recibe la sinopsis reescrita, como grupo experimental, y el resto conserva la original, como grupo de control. El seguimiento de ambos grupos, con mediciones repetidas, permite estimar el efecto de la reescritura y descontar los cambios de comportamiento de los motores. Esas mediciones realimentan el conjunto de datos y habilitan un nuevo entrenamiento del modelo.

2. Identificación y análisis de los interesados

El proyecto se desarrolla internamente por el equipo de Analítica Avanzada de Penguin Random House Grupo Editorial. En la tabla 1 se identifican los interesados del proyecto y el rol que ocupa cada uno.

Tabla 1. Identificación de los interesados.

Rol	Nombre y Apellido	Organización	Puesto
Auspiciante	-	Penguin Random House Grupo Editorial	
Cliente	Victoria O'Donnell	Penguin Random House Grupo Editorial	Científica de Datos
Responsable	Ing. Luis José Paredes Ramirez	Penguin Random House Grupo Editorial	Machine Learning Engineer
Orientador	Dr. Ing. Juan Manuel Rodríguez	Universidad de Buenos Aires	Director del Trabajo Final
Orientador	Sebastian Pellizzeri	Penguin Random House Grupo Editorial	Codirector del Trabajo Final

- Auspiciante: la editorial aporta las horas de trabajo del responsable, el acceso a los datos internos y el crédito de la API de DataForSEO. Cualquier consumo por encima de lo previsto requiere una autorización expresa, de modo que conviene acotar las consultas al proveedor desde el diseño del conjunto de datos.
- Cliente: valida los entregables y define qué títulos integran el piloto. Su disponibilidad es acotada, por lo que las instancias de validación deben planificarse con anticipación y concentrarse en pocas reuniones.
- Orientadores: el director aporta el encuadre metodológico y la supervisión académica del trabajo final. El codirector aporta el conocimiento del negocio editorial y de los sistemas internos. Este último también fija prioridades dentro de la empresa.

3. Propósito del proyecto

El propósito de este proyecto es aumentar la visibilidad del catálogo de la editorial en los motores generativos, medida como la tasa de citación de sus fichas en las respuestas, sin resignar el posicionamiento orgánico ya consolidado.

4. Alcance del proyecto

El proyecto incluye:

- La construcción del conjunto de datos de citación.

- Diseño del conjunto de consultas de descubrimiento y del protocolo de medición.
- Medición repetida de la citación del catálogo en las respuestas con búsqueda web de los motores generativos.
 - Para el motor generativo de ChatGPT se utiliza la API de OpenAI.
 - Para el motor generativo AI Overviews de Google se utiliza la API de DataForSEO.
- Incorporación de los datos internos de la editorial: catálogo, series históricas de Google Trends y resultados de proyectos de SEO previos.
- Consolidación, limpieza y versionado del conjunto de datos.
- El análisis exploratorio de los datos y la construcción de las variables predictoras.
- El desarrollo del modelo de predicción de la probabilidad de citación.
 - Entrenamiento y comparación entre modelos de aprendizaje automático.
 - Definición de la métrica de priorización de características de contenido por libro.
 - Validación mediante mediciones repetidas y controles de paráfrasis.
- El desarrollo del generador de sinopsis basado en un LLM comercial, con sus restricciones de extensión, tono y fidelidad, que aplica las técnicas de GEO compatibles con una sinopsis.
- El módulo de verificación automática de las sinopsis candidatas: fidelidad semántica respecto del texto original, extensión y presencia efectiva de las características priorizadas.
- La ejecución de un piloto controlado sobre un conjunto de títulos comparables por género y popularidad, dividido en un grupo experimental, que recibe las sinopsis aprobadas, y un grupo de control, que conserva las originales, con seguimiento de la citación de ambos grupos durante la ventana de medición acordada.
- La documentación del sistema, el código fuente y la memoria del trabajo final.

El presente proyecto no incluye:

- La optimización de otros factores de GEO distintos de la sinopsis, tales como la estructura del sitio, los datos estructurados, las páginas de autor o de género y la presencia en fuentes externas de alta citación.
- Las respuestas que los motores generan sin realizar una búsqueda web, sobre las que la sinopsis publicada no tiene influencia.
- El entrenamiento o el alojamiento de un modelo de lenguaje propio, dado que se utilizan API comerciales.
- Cualquier intervención sobre los corpus de entrenamiento de los motores o la colocación paga en sus respuestas.
- La integración productiva con el gestor de contenidos de la tienda en línea: la carga de las sinopsis del piloto se realiza por los canales que la editorial ya utiliza.
- El despliegue sobre la totalidad del catálogo ni la puesta en producción del sistema.
- La medición del impacto en ventas o en ingresos, que excede la ventana temporal del proyecto.
- La regionalización hacia otros mercados distintos de Argentina.
- La comparación con catálogos de otras editoriales.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se asume que:

- La editorial mantiene la autorización para utilizar el catálogo, las sinopsis y los datos internos de posicionamiento con fines académicos, y admite la publicación de resultados agregados en la memoria del trabajo final.
- El acceso a la API de DataForSEO continúa vigente durante toda la ejecución y el crédito contratado alcanza para el volumen de consultas previsto.
- Se dispone de acceso a las API de los motores generativos evaluados, con un crédito suficiente para el volumen de mediciones repetidas previsto y un costo por consulta compatible con el presupuesto asignado.
- Las API utilizadas informan si cada respuesta incluyó una búsqueda web y cuáles fueron las fuentes citadas.
- El comportamiento de búsqueda de los motores consultados mediante sus API es representativo del que observan los usuarios en las aplicaciones de cada motor.
- El conjunto acotado de consultas de descubrimiento representa de forma adecuada las intenciones reales de los lectores para los géneros incluidos en el estudio.
- El catálogo contiene suficientes títulos comparables por género y popularidad para conformar un grupo experimental y un grupo de control de tamaño adecuado, y la editorial admite mantener sin cambios las sinopsis del grupo de control durante la ventana de medición.
- El área de marketing digital habilita la publicación de las sinopsis del piloto dentro de los plazos planificados.
- Los cambios de comportamiento de los motores generativos durante la ventana de medición afectan por igual al grupo experimental y al grupo de control, de modo que la comparación entre ambos aísla el efecto de las sinopsis modificadas. Las mediciones se repiten para atenuar la variabilidad entre ejecuciones.
- Los datos históricos de posicionamiento cubren un período suficiente para entrenar y validar el modelo.
- El responsable dispone de una carga horaria semanal sostenida y compatible con el cronograma, y cuenta con el equipamiento y los servicios de cómputo necesarios.
- Las condiciones macroeconómicas no alteran de forma significativa el costo en pesos de los servicios contratados en moneda extranjera.

6. Product Backlog

Los requerimientos deben enumerarse y de ser posible estar agrupados por afinidad, por ejemplo:

1. Requerimientos funcionales:

- 1.1. El sistema debe...
- 1.2. Tal componente debe...
- 1.3. El usuario debe poder...
2. Requerimientos de documentación:
 - 2.1. Requerimiento 1.
 - 2.2. Requerimiento 2 (prioridad menor)
3. Requerimiento de testing...
4. Requerimientos de la interfaz...
5. Requerimientos interoperabilidad...
6. etc...

Leyendo los requerimientos se debe poder interpretar cómo será el proyecto y su funcionalidad.

Indicar claramente cuál es la prioridad entre los distintos requerimientos y si hay requerimientos opcionales.

!!!No olvidarse de que los requerimientos incluyen a las regulaciones y normas vigentes!!!

Y al escribirlos seguir las siguientes reglas:

- Ser breve y conciso (nadie lee cosas largas).
- Ser específico: no dejar lugar a confusiones.
- Expresar los requerimientos en términos que sean cuantificables y medibles.

7. Historias de usuarios (*Product backlog*)

Descripción: en esta sección se deben incluir las historias de usuarios y su ponderación (*history points*). Recordar que las historias de usuarios son descripciones cortas y simples de una característica contada desde la perspectiva de la persona que desea la nueva capacidad, generalmente un usuario o cliente del sistema. La ponderación es un número entero que representa el tamaño de la historia comparada con otras historias de similar tipo.

Se debe indicar explícitamente el criterio para calcular los *story points* de cada historia.

El formato propuesto es:

1. “Como [rol] quiero [tal cosa] para [tal otra cosa].”
Story points: 8 (complejidad: 3, dificultad: 2, incertidumbre: 3)

8. Entregables principales del proyecto

Los entregables del proyecto son (ejemplo):

- Manual de usuario.
- Diagrama de circuitos esquemáticos.
- Código fuente del firmware.
- Diagrama de instalación.
- Memoria del trabajo final.
- etc...

9. Desglose del trabajo en tareas

El WBS debe tener relación directa o indirecta con los requerimientos. Son todas las actividades que se harán en el proyecto para dar cumplimiento a los requerimientos. Se recomienda mostrar el WBS mediante una lista indexada:

1. Grupo de tareas 1 (suma h)
 - 1.1. Tarea 1 (tantas h)
 - 1.2. Tarea 2 (tantas h)
 - 1.3. Tarea 3 (tantas h)
2. Grupo de tareas 2 (suma h)
 - 2.1. Tarea 1 (tantas h)
 - 2.2. Tarea 2 (tantas h)
 - 2.3. Tarea 3 (tantas h)
3. Grupo de tareas 3 (suma h)
 - 3.1. Tarea 1 (tantas h)
 - 3.2. Tarea 2 (tantas h)
 - 3.3. Tarea 3 (tantas h)
 - 3.4. Tarea 4 (tantas h)
 - 3.5. Tarea 5 (tantas h)

Cantidad total de horas: tantas.

¡Importante!: la unidad de horas es h y va separada por espacio del número. Es incorrecto escribir “23hs”.

Se recomienda que no haya ninguna tarea que lleve más de 40 h. De ser así se recomienda dividirla en tareas de menor duración.

10. Diagrama de Activity On Node

Armaz el AoN a partir del WBS definido en la etapa anterior.

Una herramienta simple para desarrollar los diagramas es el Draw.io (<https://app.diagrams.net/>). Draw.io




Figura 2. Diagrama de *Activity on Node*.

Indicar claramente en qué unidades están expresados los tiempos. De ser necesario indicar los caminos semi críticos y analizar sus tiempos mediante un cuadro. Es recomendable usar colores y un cuadro indicativo describiendo qué representa cada color.

11. Diagrama de Gantt

Existen muchos programas y recursos *online* para hacer diagramas de Gantt, entre los cuales destacamos:

- Planner
- GanttProject
- Trello + *plugins*. En el siguiente link hay un tutorial oficial:
<https://blog.trello.com/es/diagrama-de-gantt-de-un-proyecto>
- Creately, herramienta online colaborativa.
<https://creately.com/diagram/example/ieb3p3ml/LaTeX>
- Se puede hacer en latex con el paquete *pgfgantt*
<http://ctan.dcc.uchile.cl/graphics/pgf/contrib/pgfgantt/pgfgantt.pdf>

Pegar acá una captura de pantalla del diagrama de Gantt, cuidando que la letra sea suficientemente grande como para ser legible. Si el diagrama queda demasiado ancho, se puede pegar primero la “tabla” del Gantt y luego pegar la parte del diagrama de barras del diagrama de Gantt.

Configurar el software para que en la parte de la tabla muestre los códigos del EDT (WBS).
Configurar el software para que al lado de cada barra muestre el nombre de cada tarea.
Revisar que la fecha de finalización coincida con lo indicado en el Acta Constitutiva.

En la figura 3, se muestra un ejemplo de diagrama de gantt realizado con el paquete de *pgfgantt*.
En la plantilla pueden ver el código que lo genera y usarlo de base para construir el propio.

Las fechas pueden ser calculadas utilizando alguna de las herramientas antes citadas. Sin embargo, el siguiente ejemplo fue elaborado utilizando esta hoja de cálculo.

Es importante destacar que el ancho del diagrama estará dado por la longitud del texto utilizado para las tareas (Ejemplo: tarea 1, tarea 2, etcétera) y el valor *x unit*. Para mejorar la apariencia del diagrama, es necesario ajustar este valor y, quizás, acortar los nombres de las tareas.




Figura 3. Diagrama de gantt de ejemplo




Figura 4. Ejemplo de diagrama de Gantt (apaisado).

12. Presupuesto detallado del proyecto

Si el proyecto es complejo entonces separarlo en partes:

- Un total global, indicando el subtotal acumulado por cada una de las áreas.
- El desglose detallado del subtotal de cada una de las áreas.

IMPORTANTE: No olvidarse de considerar los **COSTOS INDIRECTOS**.

Incluir la aclaración de si se emplea como moneda el peso argentino (ARS) o si se usa moneda extranjera (USD, EUR, etc). Si es en moneda extranjera se debe indicar la tasa de conversión respecto a la moneda local en una fecha dada.

COSTOS DIRECTOS			
Descripción	Cantidad	Valor unitario	Valor total
SUBTOTAL			
COSTOS INDIRECTOS			
Descripción	Cantidad	Valor unitario	Valor total
SUBTOTAL			
TOTAL			

13. Gestión de riesgos

a) Identificación de los riesgos (al menos cinco) y estimación de sus consecuencias:

Riesgo 1: detallar el riesgo (riesgo es algo que si ocurre altera los planes previstos de forma negativa)

- Severidad (S): mientras más severo, más alto es el número (usar números del 1 al 10). Justificar el motivo por el cual se asigna determinado número de severidad (S).
- Probabilidad de ocurrencia (O): mientras más probable, más alto es el número (usar del 1 al 10). Justificar el motivo por el cual se asigna determinado número de (O).

Riesgo 2:

- Severidad (S): X.
Justificación...

- Ocurrencia (O): Y.
Justificación...

Riesgo 3:

- Severidad (S): X.
Justificación...
- Ocurrencia (O): Y.
Justificación...

b) Tabla de gestión de riesgos: (El RPN se calcula como $RPN=S \times O$)

Riesgo	S	O	RPN	S*	O*	RPN*

Criterio adoptado:

Se tomarán medidas de mitigación en los riesgos cuyos números de RPN sean mayores a...

Nota: los valores marcados con (*) en la tabla corresponden luego de haber aplicado la mitigación.

c) Plan de mitigación de los riesgos que originalmente excedían el RPN máximo establecido:

Riesgo 1: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).
Nueva asignación de S y O, con su respectiva justificación:

- Severidad (S*): mientras más severo, más alto es el número (usar números del 1 al 10). Justificar el motivo por el cual se asigna determinado número de severidad (S).
- Probabilidad de ocurrencia (O*): mientras más probable, más alto es el número (usar del 1 al 10). Justificar el motivo por el cual se asigna determinado número de (O).

Riesgo 2: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).

Riesgo 3: plan de mitigación (si por el RPN fuera necesario elaborar un plan de mitigación).

14. Gestión de la calidad

Elija al menos diez requerimientos que a su criterio sean los más importantes/críticos/que aportan más valor y para cada uno de ellos indique las acciones de verificación y validación que permitan asegurar su cumplimiento.

- Req #1: copiar acá el requerimiento con su correspondiente número.

- Verificación para confirmar si se cumplió con lo requerido antes de mostrar el sistema al cliente. Detallar.
- Validación con el cliente para confirmar que está de acuerdo en que se cumplió con lo requerido. Detallar.

Tener en cuenta que en este contexto se pueden mencionar simulaciones, cálculos, revisión de hojas de datos, consulta con expertos, mediciones, etc.

Las acciones de verificación suelen considerar al entregable como “caja blanca”, es decir se conoce en profundidad su funcionamiento interno.

En cambio, las acciones de validación suelen considerar al entregable como “caja negra”, es decir, que no se conocen los detalles de su funcionamiento interno.

15. Procesos de cierre

Establecer las pautas de trabajo para realizar una reunión final de evaluación del proyecto, tal que contemple las siguientes actividades:

- Pautas de trabajo que se seguirán para analizar si se respetó el Plan de Proyecto original:
 - Indicar quién se ocupará de hacer esto y cuál será el procedimiento a aplicar.
- Identificación de las técnicas y procedimientos útiles e inútiles que se emplearon, los problemas que surgieron y cómo se solucionaron:
 - Indicar quién se ocupará de hacer esto y cuál será el procedimiento para dejar registro.
- Indicar quién organizará el acto de agradecimiento a todos los interesados, y en especial al equipo de trabajo y colaboradores:
 - Indicar esto y quién financiará los gastos correspondientes.