Presentación del plan de trabajo final

Carrera de Especialización en Inteligencia Artificial

Optimización de sinopsis de libros para motores de búsqueda generativa (GEO) mediante la predicción de la probabilidad de citación con aprendizaje automático

Autor
Ing. Luis José Paredes Ramirez

Director
Dr. Ing. Juan Manuel Rodríguez
Universidad de Buenos Aires

Codirector
Sebastian Pellizzeri
Penguin Random House Grupo Editorial

.UBAfiuba FACULTAD DE INGENIERÍA

Penguin Random House Grupo Editorial

¿Qué es SEO?

Optimización para motores de búsqueda (SEO): se busca mejorar la posición de un sitio en la página de resultados (SERP)

Consulta

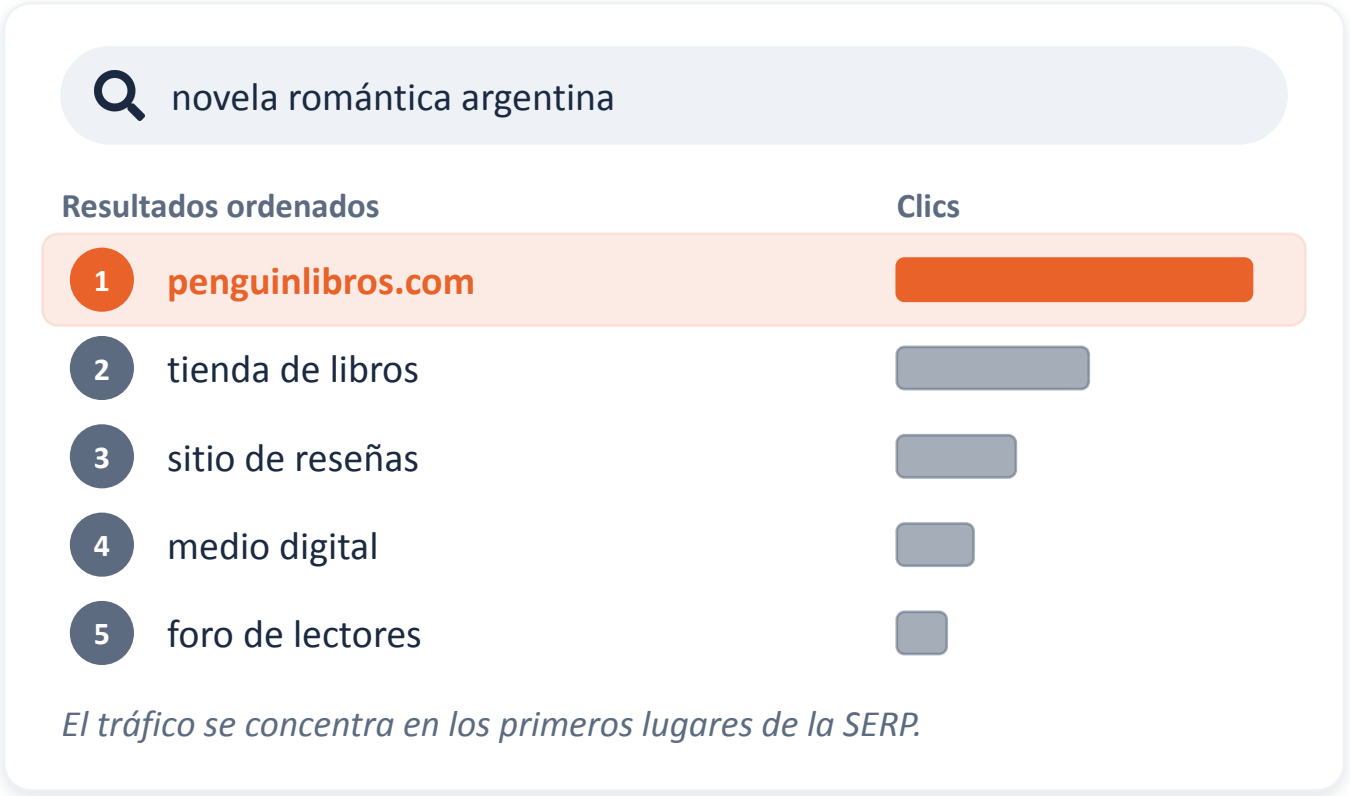
El usuario realiza una búsqueda.

Ranking

El buscador rastrea, indexa y ordena las páginas.

Click

El lector elige una página dentro del SERP y visita el sitio.



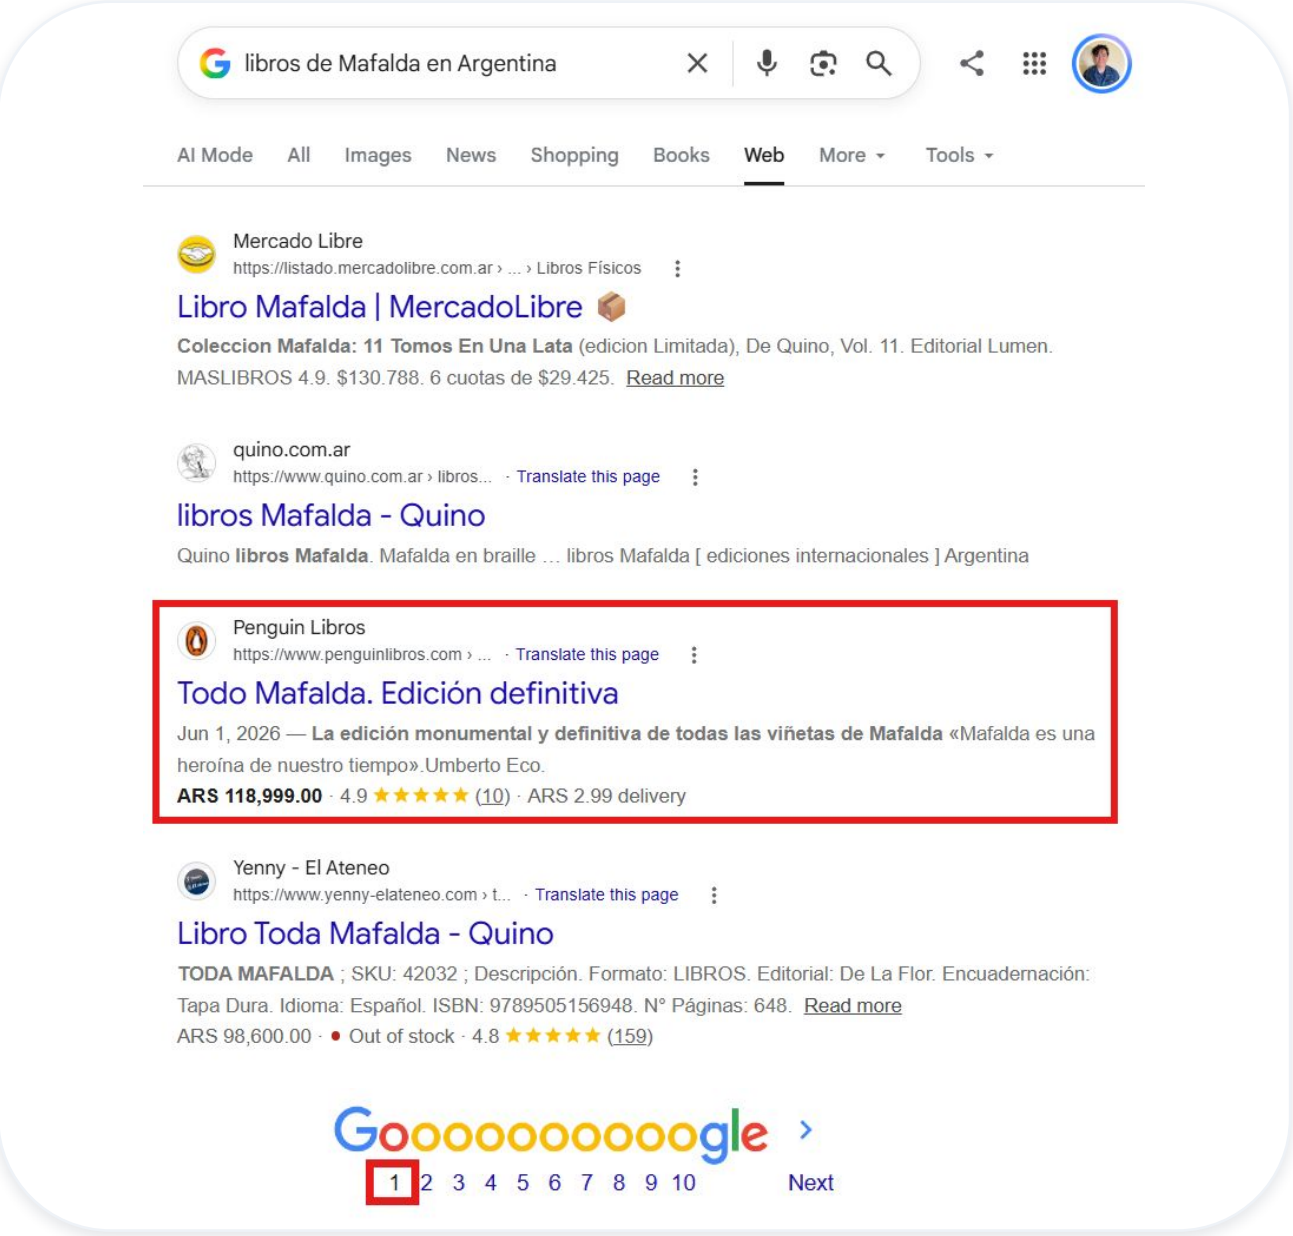
El tráfico se concentra en los primeros lugares de la SERP.

Unidad de éxito: rankear alto en el SERP · métricas: ranking, clicks through rate y tráfico orgánico

¿Qué es SEO?

Unidad de éxito

Rankear alto en el SERP



¿Qué es GEO?

Optimización para motores de búsqueda generativa (GEO): se busca que un contenido sea citado en la respuesta

Pregunta

El lector consulta en lenguaje natural.

Búsqueda web

El motor reformula la consulta y realiza múltiples búsquedas web en paralelo.

Respuesta con citas

Un LLM sintetiza la información y cita las fuentes en su respuesta.

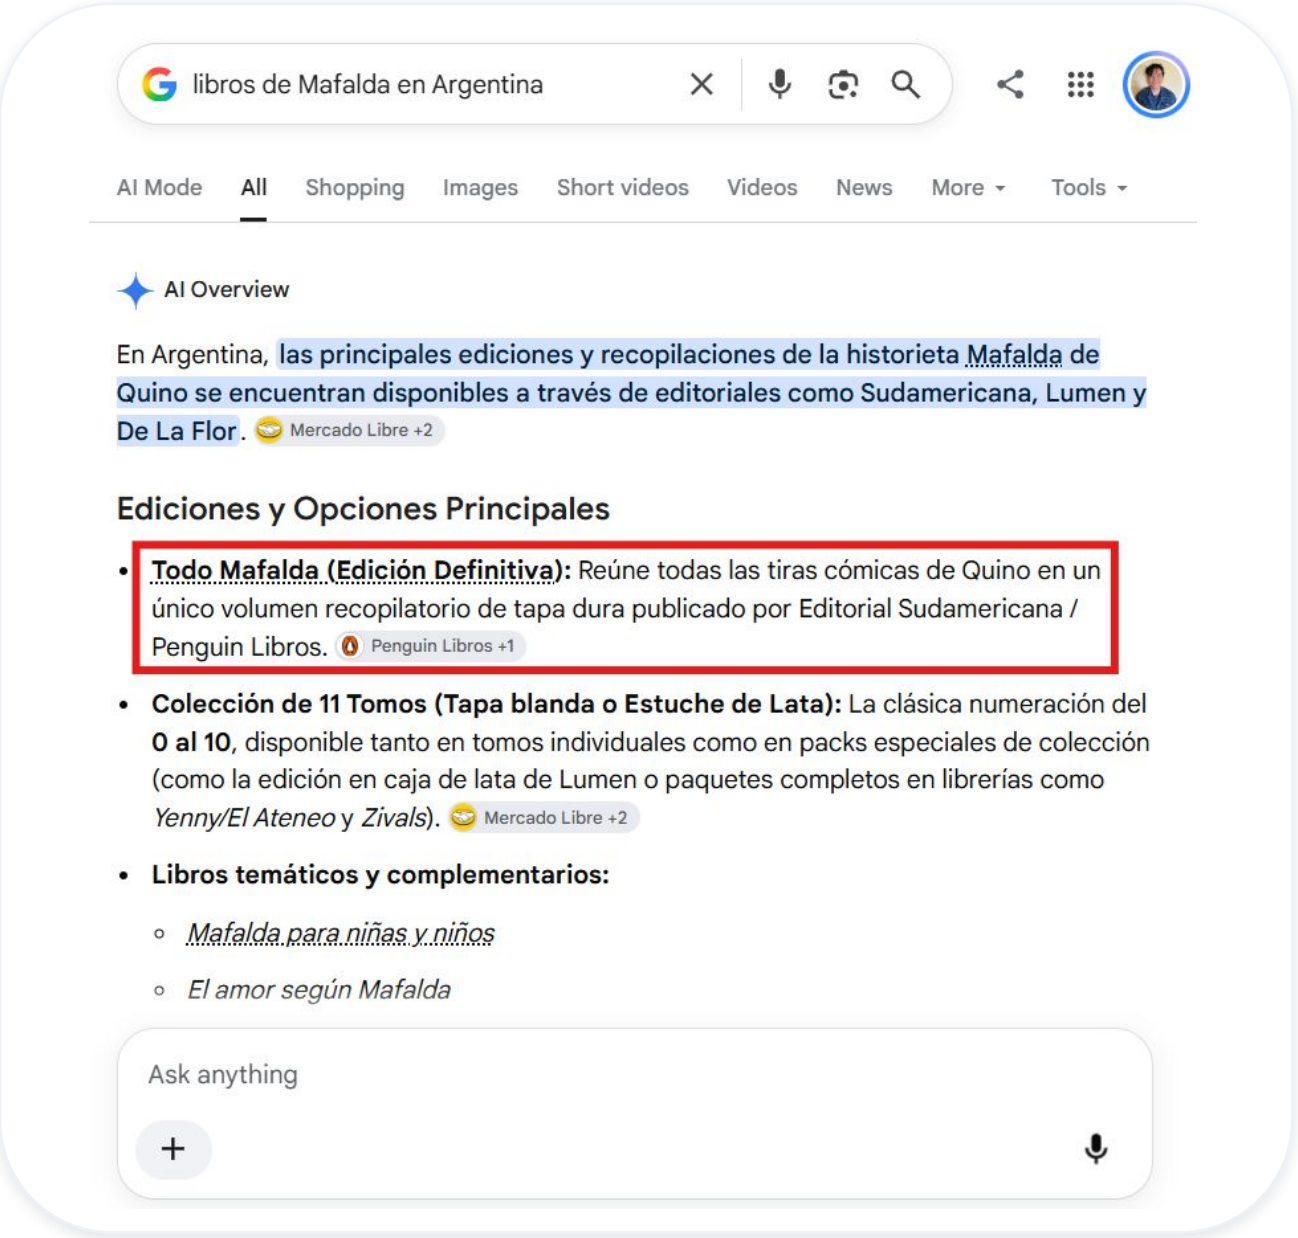


Unidad de éxito: ser citado en la respuesta

¿Qué es GEO?

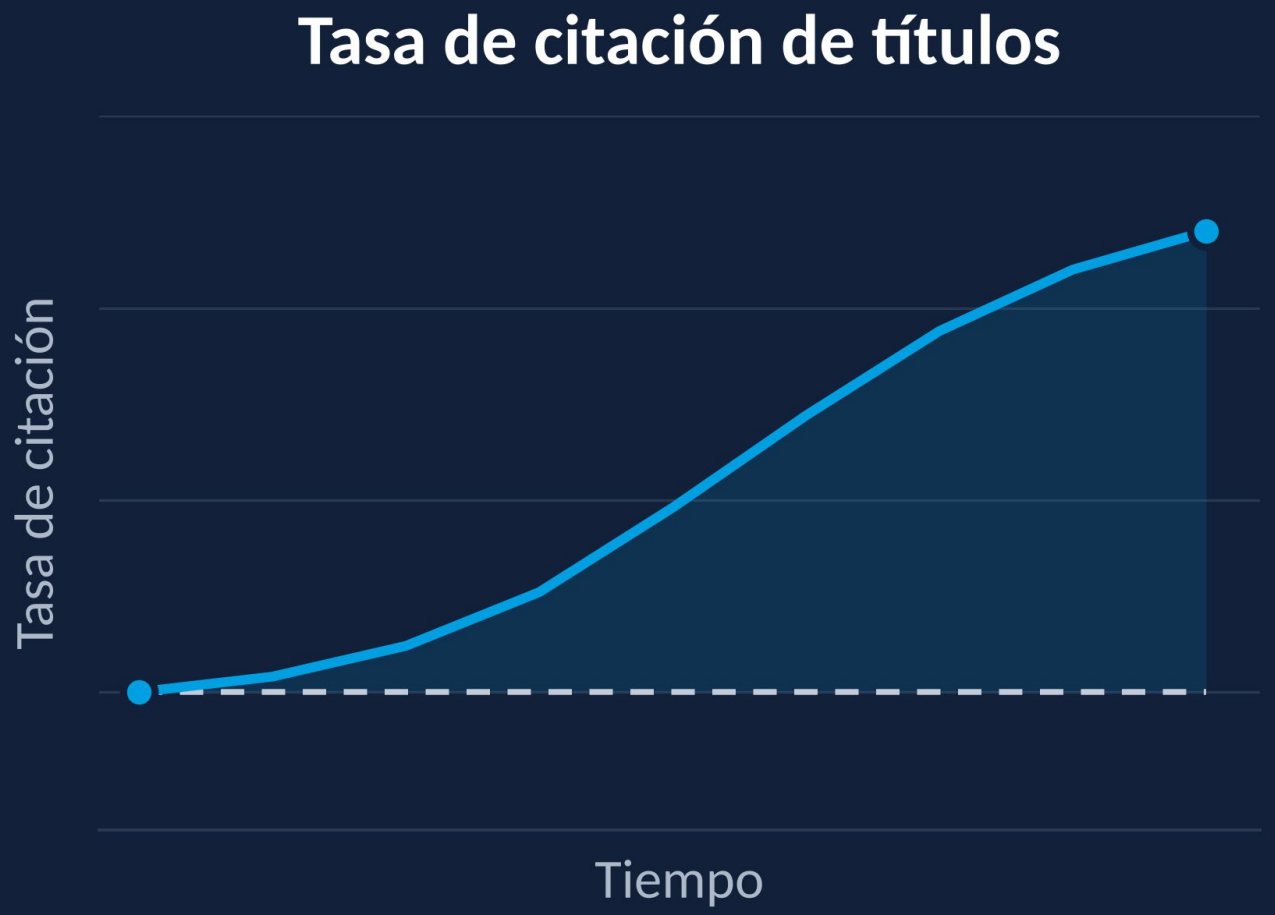
Unidad de éxito

Ser citado en la respuesta

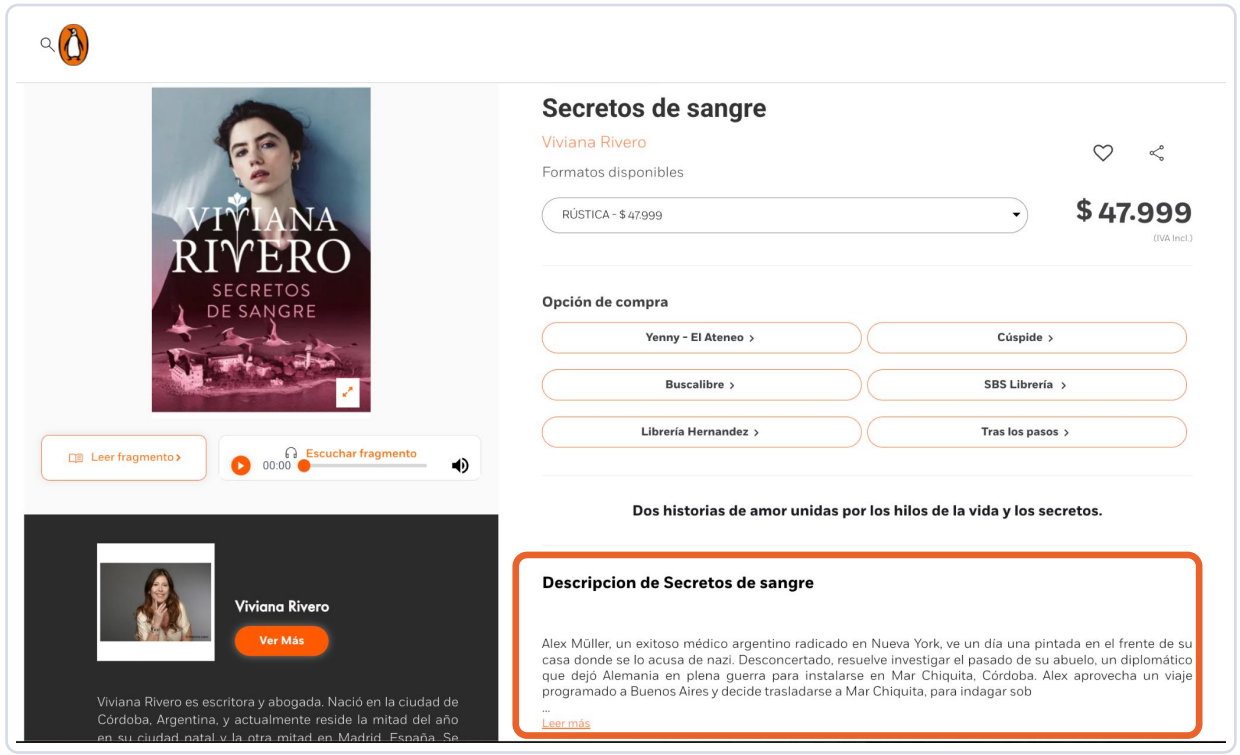


Propósito del proyecto

El propósito del proyecto es aumentar la visibilidad del catálogo de la editorial en los motores de búsqueda generativa sin resignar el posicionamiento orgánico ya consolidado.



Solución propuesta



La web de PenguinLibros cuenta con un activo digital sumamente valioso para la IA: la sinopsis de cada libro del catálogo.

Medir

Qué títulos citan hoy los motores generativos.

Aprender

Qué características de la sinopsis favorecen la cita.

Reescribir

La IA propone una sinopsis y el equipo editorial la aprueba.

Comprobar

Un piloto compara las fichas nuevas con un grupo de control.

Interesados

Auspiciante	**Penguin Random House Grupo Editorial**	Aporta datos internos y créditos para las APIs
Cliente	**Victoria O'Donnell**	Científica de datos Penguin Random House Grupo Editorial
Responsable	**Ing. Luis José Paredes Ramirez**	*Machine learning engineer* Penguin Random House Grupo Editorial
Orientador	**Dr. Ing. Juan Manuel Rodríguez**	Director del trabajo final Universidad de Buenos Aires
Orientador	**Sebastian Pellizzeri**	Codirector del trabajo final Penguin Random House Grupo Editorial

Alcance

Incluye

- Construcción del conjunto de datos de citación.
- Análisis y extracción de características principales.
- Modelo de predicción de la citación.
- Generador de sinopsis con un LLM comercial.
- Piloto controlado con grupo de control.
- Documentación, código fuente y memoria.

No incluye

- Factores de GEO distintos de la sinopsis.
- Respuestas generadas sin búsqueda web.
- Entrenamiento de un LLM propio.
- Despliegue en todo el catálogo.
- Medición del impacto en ventas.
- Otros mercados u otras editoriales.

Requerimientos

Product backlog con 4 épicas y 8 historias de usuario (HU), que suman 115 *story points* (SP)

1 Épica 1

Construcción del conjunto de datos de citación

HU1 21 SP · alta

Medir la citación de los títulos en los motores.

HU2 13 SP · alta

Consolidar la posición de las fichas y la popularidad.

2 Épica 2

Predicción de la probabilidad de citación

HU3 13 SP · alta

Entrenar un modelo que priorice las características.

HU4 13 SP · alta

Validar el modelo con mediciones repetidas.

3 Épica 3

Generación y verificación de sinopsis

HU5 13 SP · alta

Sugerir una sinopsis optimizada para la citación.

HU6 13 SP · media

Preservar la fidelidad de la sinopsis original.

4 Épica 4

Piloto y medición de resultados

HU7 21 SP · alta

Medir la mejora frente a un grupo de control.

HU8 8 SP · media

Contar con un informe claro de los resultados.

Fases de CRISP-DM

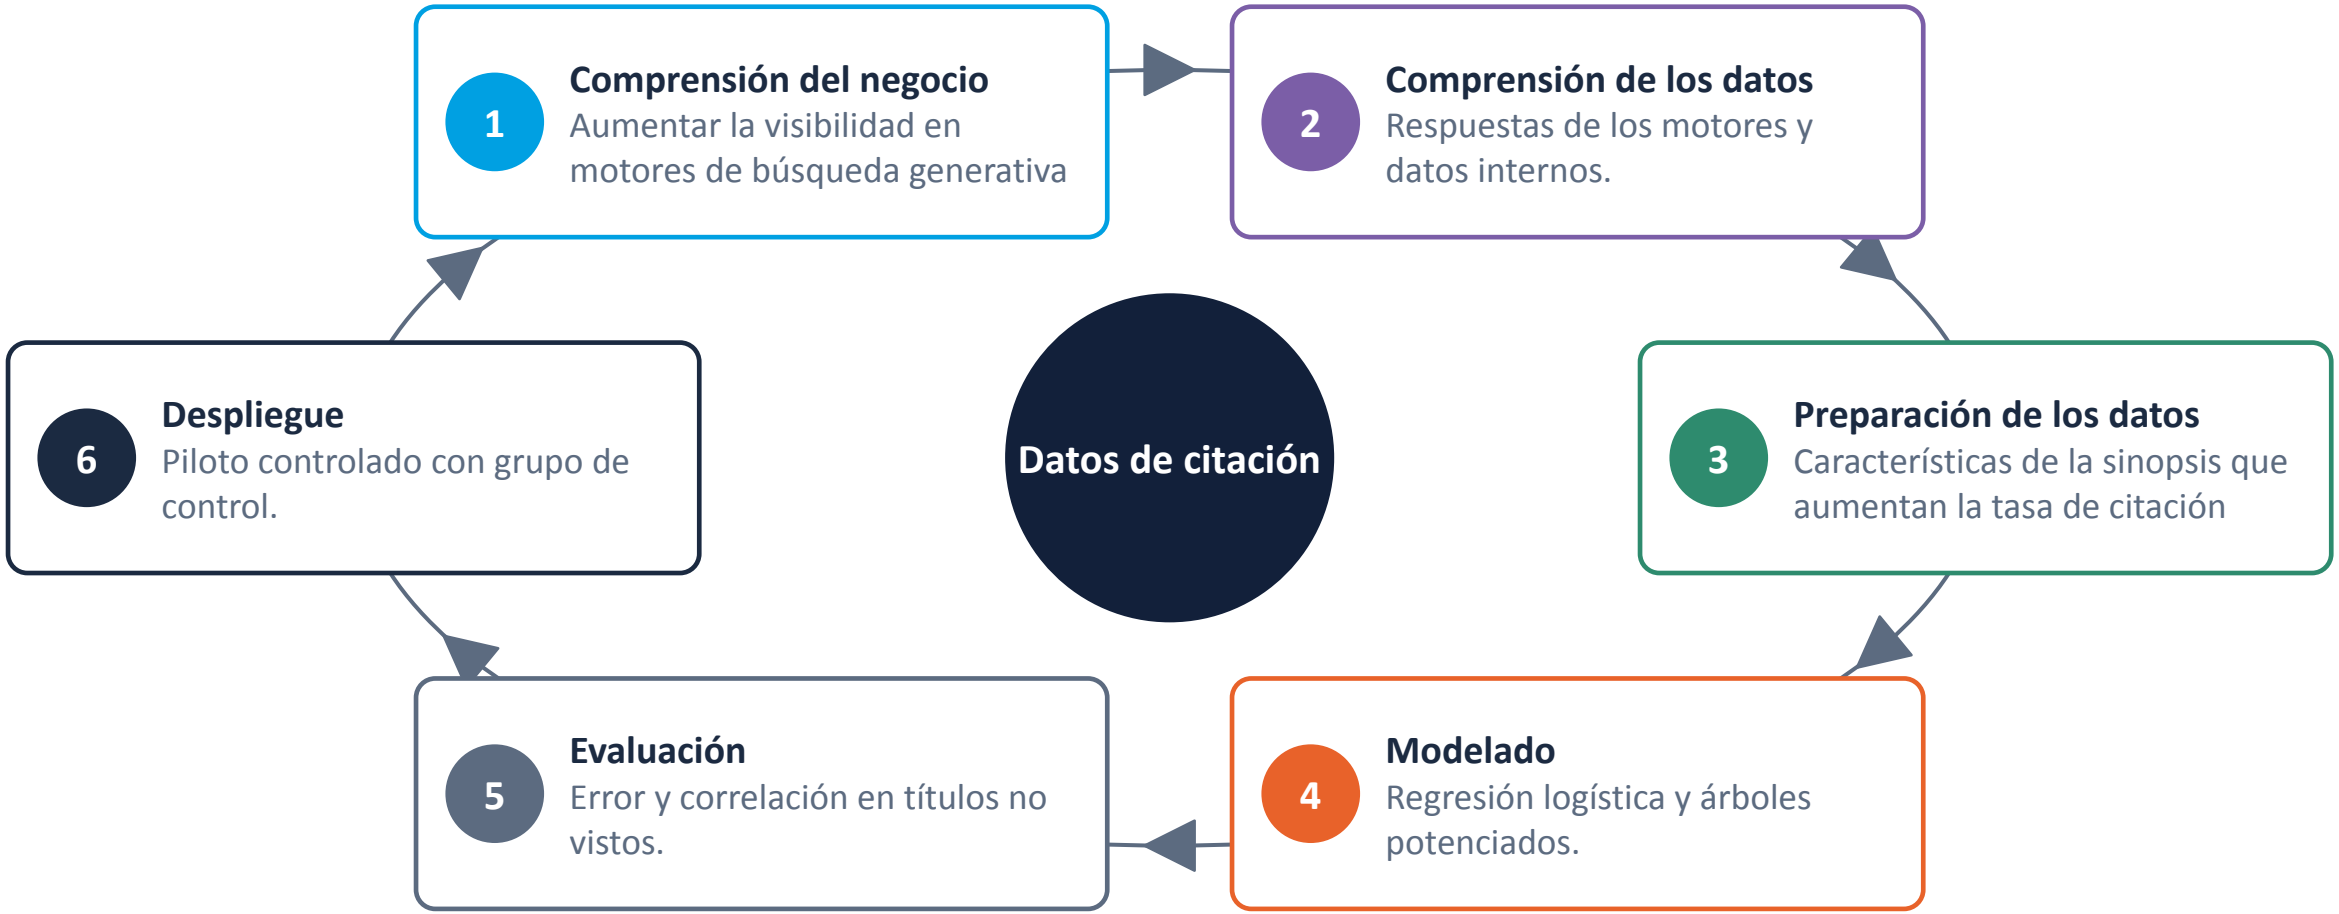
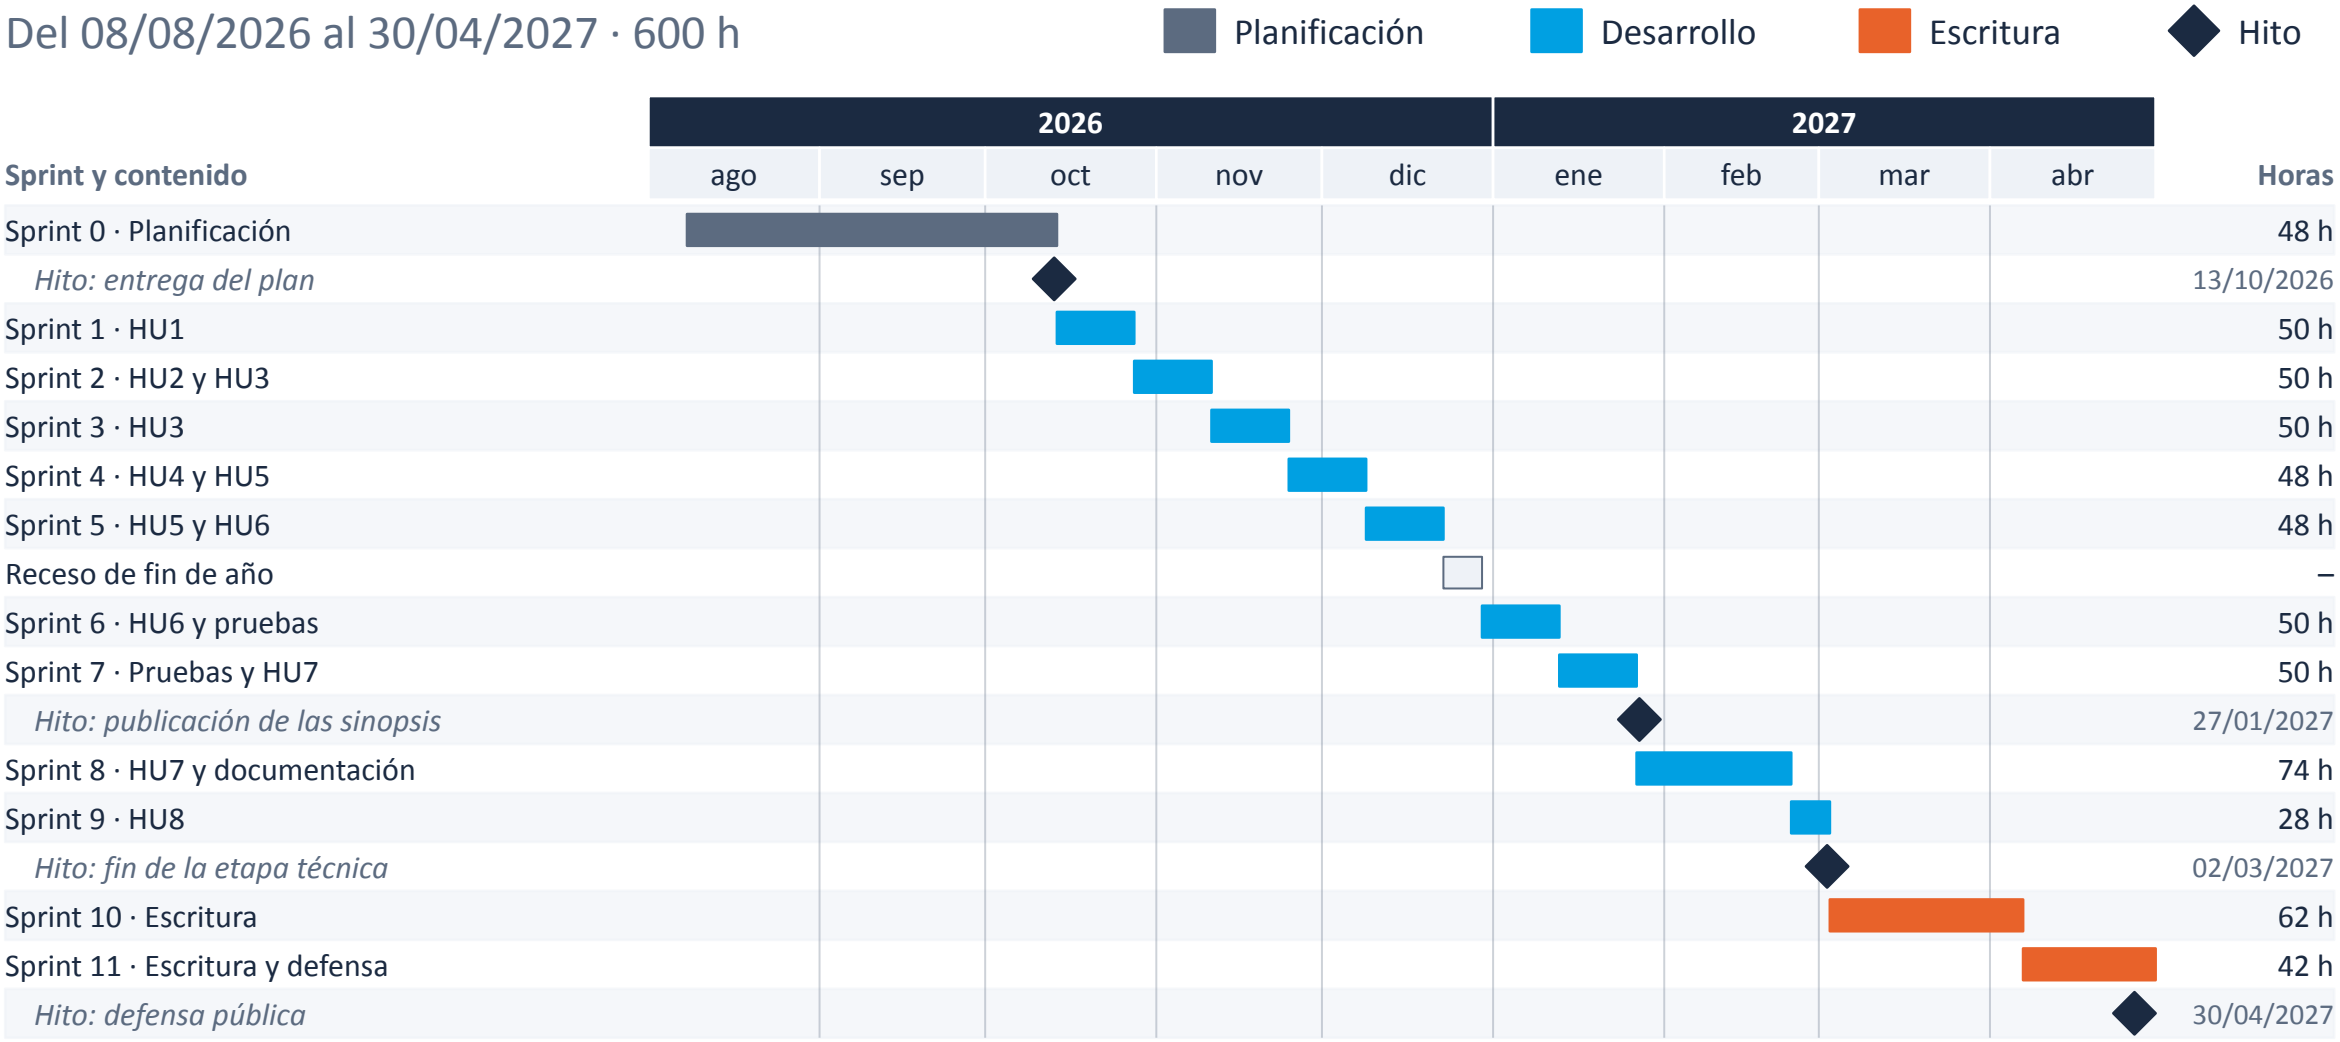


Diagrama de Gantt

Del 08/08/2026 al 30/04/2027 · 600 h



Sprint y contenido	Horas
Sprint 0 · Planificación	48 h
Hito: entrega del plan	13/10/2026
Sprint 1 · HU1	50 h
Sprint 2 · HU2 y HU3	50 h
Sprint 3 · HU3	50 h
Sprint 4 · HU4 y HU5	48 h
Sprint 5 · HU5 y HU6	48 h
Receso de fin de año	–
Sprint 6 · HU6 y pruebas	50 h
Sprint 7 · Pruebas y HU7	50 h
Hito: publicación de las sinopsis	27/01/2027
Sprint 8 · HU7 y documentación	74 h
Sprint 9 · HU8	28 h
Hito: fin de la etapa técnica	02/03/2027
Sprint 10 · Escritura	62 h
Sprint 11 · Escritura y defensa	42 h
Hito: defensa pública	30/04/2027

Gestión de riesgos

Severidad (S) y ocurrencia (O) de 1 a 10 · se mitigan los riesgos con RPN = S × O mayor que 25

N.°	Riesgo	S	O	RPN	Mitigación	S*	O*	RPN*
1	Escasez de citas de las fichas	9	6	**54**	Medición exploratoria en el *sprint* 1 y señal auxiliar de DataForSEO.	6	4	**24**
2	Cambios en los motores o en sus API	8	6	**48**	Versión fija del modelo, un módulo por motor y grupo de control.	5	4	**20**
3	Costo de las API superior al previsto	6	5	**30**	Presupuesto por ronda, alertas de consumo y respuestas almacenadas.	4	3	**12**
4	Demoras en la revisión o en la publicación del piloto	8	5	**40**	Fecha acordada al cierre del *sprint* 0 y respaldo del codirector.	6	3	**18**
5	Resultados no concluyentes del piloto	7	6	**42**	Análisis de potencia, asignación estratificada y métrica secundaria.	5	4	**20**
6	Caída de la posición orgánica	7	3	**21**	Bajo el umbral: se registra la posición en cada ronda.	–	–	–
7	Retiro de la autorización de uso de los datos	10	2	**20**	Bajo el umbral: autorización escrita de la editorial.	–	–	–

Sprint retrospective

Sprint	¿Qué hacer más?	¿Qué hacer menos?	¿Qué mantener?	¿Qué empezar a hacer?	¿Qué dejar de hacer?
Sprint 0 no técnico	Validaciones tempranas con el director y el codirector	Reescrituras completas por cambios de enfoque	Revisión de la redacción con la guía del taller gramatical	Registrar cada decisión y su motivo	Postergar la estimación de horas hasta el final del plan
Sprint 1 técnico	Pruebas de las consultas sobre muestras pequeñas	Consultas manuales a los motores fuera de protocolo	Registro del motor y de la versión del modelo	Controlar a diario el consumo de las API	Ejecutar rondas completas sin validar el formato de las respuestas
Sprint 3 técnico	Contraste con el modelo de referencia	Ajustes de hiper parámetros sin registro	Validación cruzada agrupada por título	Validar las prioridades sobre una muestra de títulos	Agregar variables sin documentar su origen
Sprint 8 técnico	Seguimiento semanal de ambos grupos del piloto	Cambios en las sinopsis publicadas durante la medición	Mediciones repetidas con el mismo protocolo	Documentar cada módulo al cerrarlo	Interpretar resultados parciales como definitivos
Sprint 11 no técnico	Ensayos de la exposición con devolución del director	Cambios de contenido en la memoria cerca de la entrega	Material visual claro sobre los resultados del piloto	Ensayar la defensa con tiempo límite y preguntas simuladas	Agregar detalles técnicos que no aportan a las conclusiones

Muchas gracias

¿Preguntas?

De ranking a citas. De tráfico a influencia medible.

Ing. Luis José Paredes Ramirez



